ニューラルネットワークの最適化

勾配の前処理から考える

石川智貴

目次

第 1 章 はじめに ・・・

4.3.1 収束速度と更新ノイズ ・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・ 31
4.3.2 ノイズによる学習率の制限 ・・・・・・・・・・・・・・・・・・・・・・・・・・・・・ 32
4.3.3 速い更新に必要なバッチサイズ ・・・・・・・・・・・・・・・・・・・・・・・・・・・ 33
4.4 確率的分散縮小アルゴリズム・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・ 33
第 5 章 線形ネットワーク ・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・ 35
5.1 自然勾配法の学習ダイナミクス ・・・・・・・・・・・・・・・・・・・・・・・・・・・・・ 35
5.1.1 線形ネットワークと回帰問題・・・・・・・・・・・・・・・・・・・・・・・・・・・・・ 35
5.1.2 通常の勾配とフィッシャー情報行列・・・・・・・・・・・・・・・・・・・・・・・・・・ 36
5.1.3 各層の自然勾配を求める・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・ 37
5.1.4 積行列と損失の指数収束・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・ 38
5.2 Saxe Solution と Fukumizu Solution・・・・・・・・・・・・・・・・・・・・・・・・・・ 39
5.2.1 特異値ごとの力学系 ・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・ 39
5.2.2 Saxe 解：モードごとの学習曲線 ・・・・・・・・・・・・・・・・・・・・・・・・・・・ 40
5.2.3 Fukumizu 解：モードの結合を行列のまま解く ・・・・・・・・・・・・・・・・・・・・ 40
5.3 前処理勾配法における Saxe Solution ・・・・・・・・・・・・・・・・・・・・・・・・・・ 42
5.3.1 NGD：積行列の誤差に比例する更新 ・・・・・・・・・・・・・・・・・・・・・・・・・ 42
5.3.2 Muon：各層の特異値を一定の速さで動かす更新 ・・・・・・・・・・・・・・・・・・・ 42
第 6 章 学習レジーム ・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・ 45
6.1 Neural Tangent Kernel・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・ 45
6.1.1 NTK regime と線形化された学習ダイナミクス ・・・・・・・・・・・・・・・・・・・・ 45
6.1.2 NTK regime での自然勾配法 ・・・・・・・・・・・・・・・・・・・・・・・・・・・・ 47
6.2 特徴学習 ・・ 48
第 7 章 ホップフィールドネットワーク・・・・・・・・・・・・・・・・・・・・・・・・・・・ 49
第 8 章 ハイパーパラメータの設定・・・・・・・・・・・・・・・・・・・・・・・・・・・・・ 51
付録 A NTK regime の保証 ・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・ 53
A.1 二層ネットワークでの局所評価 ・・・・・・・・・・・・・・・・・・・・・・・・・・・・ 53
A.2 学習軌道が初期値近傍に留まること ・・・・・・・・・・・・・・・・・・・・・・・・・・ 54
A.3 ガウス初期値で条件を満たす確率・・・・・・・・・・・・・・・・・・・・・・・・・・・・ 55
A.4 線形化モデルとの出力の差・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・・ 56
参考文献・・・ 57

第 1 章　はじめに

ニューラルネットワークの学習では，損失の勾配を計算してパラメータを更新する．この仕組みを学ぶとき，最初に習うのは，勾配と逆の方向へ学習率を掛けた分だけ進む勾配降下法や，ミニバッチで勾配を推定する確率的勾配降下法（SGD）である．ところが，実際の学習で使う最適化手法には，AdamW や Muon といった名前が並ぶ．これらの手法では，計算した勾配に対して，前処理を行ってから更新に使う．

実際の学習に即して最適化を理解するには，実際に使われている最適化手法，つまり，前処理を含む更新則を常に考慮にいれるのが自然だろう．本原稿では，この立場から，前処理勾配法を中心にニューラルネットワークの最適化を概観する．

第 2 章　近接項から見る前処理勾配法

損失を小さくするには，現在のパラメータをどのように更新すればよいだろうか．ここでは，損失を減らすことと，現在の点から大きく離れすぎないことを，一つの最小化問題で考える．更新量を抑える項を近接項と呼び，損失の近似と組み合わせることで，勾配を使った更新を導く．この見方では，前処理にも自然な意味がある．何をもって「近い」とするかを変えると，勾配に施す前処理も変わるのである．まず，通常の勾配降下法をこの視点から導く．

2.1　近接項による更新の定式化

2.1.1　勾配降下法

微分可能な損失関数を $\mathcal{L}\colon \mathbb{R}^d \to \mathbb{R}$ とし，第 k 回の反復におけるパラメータを $\boldsymbol{\theta}^{(k)}$ と書く．損失を小さくすると同時に，現在のパラメータから大きく離れないよう，近接点法では

$$\boldsymbol{\theta}^{(k+1)} = \operatorname*{argmin}_{\boldsymbol{u}} \left\{ \mathcal{L}(\boldsymbol{u}) + \frac{\lambda}{2} \|\boldsymbol{u} - \boldsymbol{\theta}^{(k)}\|_2^2 \right\}, \qquad \lambda > 0 \tag{2.1}$$

を解く[1)]．第 1 項が損失，第 2 項が更新量を抑える近接項である．λ を大きくするほど，現在の点から離れることへの重みが増す．

最小解では $\boldsymbol{u}$ についての勾配がゼロになるので，

$$\nabla \mathcal{L}(\boldsymbol{\theta}^{(k+1)}) + \lambda(\boldsymbol{\theta}^{(k+1)} - \boldsymbol{\theta}^{(k)}) = \mathbf{0} \tag{2.2}$$

が成り立つ．$\eta := 1/\lambda$ とおき，更新後のパラメータについて整理すると，

$$\boldsymbol{\theta}^{(k+1)} = \boldsymbol{\theta}^{(k)} - \eta \nabla \mathcal{L}(\boldsymbol{\theta}^{(k+1)}) \tag{2.3}$$

を得る．右辺にも未知の $\boldsymbol{\theta}^{(k+1)}$ が含まれているため，これは陰的な更新式である．このままでは，現在のパラメータ $\boldsymbol{\theta}^{(k)}$ を右辺に代入するだけで，次のパラメータ $\boldsymbol{\theta}^{(k+1)}$ を求めることはできない．更新先を求めるには，この方程式を解く必要がある[2)]．

そこで，右辺の勾配を，更新前の点での勾配に置き換えることを考える．更新量が小さく，その範囲で勾配があまり変わらない場合には，

$$\nabla \mathcal{L}(\boldsymbol{\theta}^{(k+1)}) \approx \nabla \mathcal{L}(\boldsymbol{\theta}^{(k)}) \tag{2.4}$$

---

1)　この最小解が存在すると仮定する．

2)　各反復で抽出したデータの損失を使い，この陰的な更新式を解く方法を implicit SGD と呼ぶ．陰的な更新には，学習率の選択に対して安定性を保ちやすいという利点がある [1]．たとえば，$\mathcal{L}(\theta) = h\theta^2/2$（$h > 0$）では，通常の勾配降下法は現在の値を $1 - \eta h$ 倍するのに対し，陰的な更新は $1/(1 + \eta h)$ 倍する．後者は，どの $\eta > 0$ でも最小点 0 に近づく．

と近似できる．この置き換えを式 (2.3) に用いて更新を定めると，

$$\boldsymbol{\theta}^{(k+1)} = \boldsymbol{\theta}^{(k)} - \eta \nabla \mathcal{L}(\boldsymbol{\theta}^{(k)}) \tag{2.5}$$

となる．これが勾配降下法である．右辺には更新前の点で計算できる量だけが現れ，陰的な方程式を解く必要がなくなった．ここからは，近似によって得た更新先も $\boldsymbol{\theta}^{(k+1)}$ と書く．

近接点法の最小化問題で損失そのものを一次近似しても，同じ勾配降下法が得られる．現在の勾配を $\boldsymbol{g}_k = \nabla \mathcal{L}(\boldsymbol{\theta}^{(k)})$，更新量を $\boldsymbol{\delta} = \boldsymbol{u} - \boldsymbol{\theta}^{(k)}$ とおくと，

$$\mathcal{L}(\boldsymbol{\theta}^{(k)} + \boldsymbol{\delta}) \approx \mathcal{L}(\boldsymbol{\theta}^{(k)}) + \boldsymbol{g}_k^{\top} \boldsymbol{\delta} \tag{2.6}$$

となる．式 (2.1) の損失をこの一次式に置き換え，定数項を省けば，

$$\boldsymbol{\delta}_k = \operatorname*{argmin}_{\boldsymbol{\delta}} \left\{ \boldsymbol{g}_k^{\top} \boldsymbol{\delta} + \frac{\lambda}{2} \|\boldsymbol{\delta}\|_2^2 \right\} \tag{2.7}$$

を得る．最小解は $\boldsymbol{g}_k + \lambda \boldsymbol{\delta}_k = \boldsymbol{0}$ を満たすので，$\boldsymbol{\delta}_k = -\eta \boldsymbol{g}_k$ となり，式 (2.5) と一致する．以後はこの最小化問題を使い，近接項と損失の近似を順に変えていく．

2.1.2 距離の取り方の一般化

式 (2.7) では，パラメータの変化をユークリッド距離の二乗で測った．同じ大きさの更新でも，方向によって予測の変化量は異なる．予測を大きく変えすぎないように更新したいなら，パラメータの数値の差だけでなく，モデルの出力の変化を測る方が目的に合っている．

そこで，更新前後の違いを測る非負の関数 $D(\boldsymbol{u}, \boldsymbol{\theta})$ を使う．同じパラメータでは $D(\boldsymbol{\theta}, \boldsymbol{\theta}) = 0$ とするが，対称性や三角不等式は要求しない．このような違いの尺度を，ここではダイバージェンスと呼ぶ[3]．通常の距離とは異なるが，現在の点から大きく変わる更新を抑える近接項として使える．損失の一次近似はそのままにして，更新を

$$\boldsymbol{\theta}^{(k+1)} = \operatorname*{argmin}_{\boldsymbol{u}} \left\{ \boldsymbol{g}_k^{\top} (\boldsymbol{u} - \boldsymbol{\theta}^{(k)}) + \lambda D(\boldsymbol{u}, \boldsymbol{\theta}^{(k)}) \right\} \tag{2.8}$$

と定める．$D(\boldsymbol{u}, \boldsymbol{\theta}) = \frac{1}{2}\|\boldsymbol{u} - \boldsymbol{\theta}\|_2^2$ と選べば，前項の勾配降下法に戻る．ここでは，モデルの予測分布の変化を測るために，KL ダイバージェンスを選ぶ．

たとえば，分類モデルが入力 $\boldsymbol{x}$ に対してクラス y の確率 $p_{\boldsymbol{\theta}}(y \mid \boldsymbol{x})$ を出力するとする．更新前と更新後のモデルがほぼ同じ確率分布を出力するなら，パラメータの値が異なっていても，予測の変化は小さいと考えたい．この目的には，確率分布同士の違いを測る KL ダイバージェンスを使える．有限個のクラス上の正の確率分布 p, q に対し，

$$D_{\mathrm{KL}}(p \| q) = \sum_{y} p(y) \log \frac{p(y)}{q(y)} \tag{2.9}$$

---

3) 集合 $\mathcal{X}$ 上のダイバージェンス D は，任意の $x, y \in \mathcal{X}$ に対して，(i) $D(x, y) \geq 0$，(ii) $D(x, x) = 0$，(iii) $D(x, y) = 0$ ならば $x = y$，の 3 条件を満たす関数である．対称性と三角不等式は要求しない．予測分布上のダイバージェンスをパラメータの関数として使う場合には，異なるパラメータが同じ予測分布を表しうるため，パラメータの一致を要求する (iii) は課さない．

と定義する[4]．この値は非負であり，二つの分布が一致するときにゼロになる．一般には $D_{\mathrm{KL}}(p\|q) \neq D_{\mathrm{KL}}(q\|p)$ なので，どちらの分布を基準にするかも指定する必要がある．

ここでは，更新前の予測分布を基準にして，

$$D(\boldsymbol{u}, \boldsymbol{\theta}^{(k)}) = \mathbb{E}_{\boldsymbol{x}\sim\mu}\left[D_{\mathrm{KL}}\big(p_{\boldsymbol{\theta}^{(k)}}(\cdot \mid \boldsymbol{x}) \| p_{\boldsymbol{u}}(\cdot \mid \boldsymbol{x})\big)\right] \tag{2.10}$$

と選ぶ．μ は入力をどの重みで平均するかを定める固定の分布であり，たとえば訓練入力上の経験分布を使う．この近接項は，入力ごとの予測確率が大きく変わる更新を抑える．損失が正解ラベルに対して予測を改善する役割を持つのに対し，近接項は更新前の予測からの変化を制御する．異なるパラメータが同じ予測分布を表すこともあるので，この D はパラメータが異なっていてもゼロになりうる．

この KL ダイバージェンスを使って，更新をどう計算すればよいだろうか．式 (2.10) の KL ダイバージェンスを現在の点のまわりで二次近似するため，$\boldsymbol{u}$ についてのヘッセ行列を $\boldsymbol{F} := \nabla_1^2 D(\boldsymbol{\theta}^{(k)}, \boldsymbol{\theta}^{(k)})$ と書く[5]．式 (2.10) を $\boldsymbol{u}$ で二回微分し，$\boldsymbol{u} = \boldsymbol{\theta}^{(k)}$ とおくと，

$$\boldsymbol{F} = \mathbb{E}_{\boldsymbol{x}\sim\mu}\left[\sum_{y} p_{\boldsymbol{\theta}^{(k)}}(y \mid \boldsymbol{x}) \boldsymbol{s}_k(y, \boldsymbol{x}) \boldsymbol{s}_k(y, \boldsymbol{x})^{\top}\right], \quad \boldsymbol{s}_k(y, \boldsymbol{x}) := \nabla_{\boldsymbol{\theta}} \log p_{\boldsymbol{\theta}}(y \mid \boldsymbol{x})|_{\boldsymbol{\theta}=\boldsymbol{\theta}^{(k)}} \tag{2.11}$$

となる．この等式には，$\sum_y p_{\boldsymbol{\theta}}(y \mid \boldsymbol{x}) = 1$ を二回微分するとゼロになることを用いた．この $\boldsymbol{F}$ はフィッシャー情報行列であり，予測分布が各パラメータ方向にどれだけ変わるかを表す[6]．

この行列を使って，KL ダイバージェンスを二次まで展開する．$D(\boldsymbol{u}, \boldsymbol{\theta}^{(k)})$ は $\boldsymbol{u} = \boldsymbol{\theta}^{(k)}$ で最小値ゼロをとるため，その点での値と勾配がゼロになる．したがって，テイラー展開では二次の項が最初に残り，

$$D(\boldsymbol{\theta}^{(k)} + \boldsymbol{\delta}, \boldsymbol{\theta}^{(k)}) = \frac{1}{2}\boldsymbol{\delta}^{\top}\boldsymbol{F}\boldsymbol{\delta} + o(\|\boldsymbol{\delta}\|_2^2) \tag{2.12}$$

を得る．$\boldsymbol{F}$ の固有値が大きい方向ほど，同じ大きさの更新に対して KL ダイバージェンスが大きく増える．予測の変化を KL ダイバージェンスで測るという選択から，近接項の行列がフィッシャー情報行列に定まった．

ここからは，$\boldsymbol{F}$ が正定値であると仮定して更新を求める．フィッシャー情報行列は一般には半正定値にとどまり，特異になりうる[7]．その場合には，たとえば $\boldsymbol{F} + \gamma\boldsymbol{I}$（$\gamma > 0$）を用いて近接項

---

4) 情報理論では，p に従うデータを q に基づいて符号化するとき，p に基づく場合よりも余分に必要になる平均符号長として解釈できる [2]．p はデータを生成する分布，q は符号化に使う分布なので，両者の役割は対称ではない．統計の言葉では，同じ量は，p を使う場合に比べた q の平均対数尤度の低下を表す．したがって，p を固定して KL ダイバージェンスを最小にすることは，モデル q の対数尤度の平均を最大にすることに等しい [3]．

5) μ は有限個の入力上の分布とし，各予測確率は正で，パラメータについて二階連続微分可能であると仮定する．現在の点 $\boldsymbol{\theta}^{(k)}$ はパラメータの定義域の内点とする．

6) フィッシャー情報行列は，もともとパラメータの推定精度を表す量として導入された．正則なモデルでは，標本数が十分に大きいとき，最尤推定量の共分散は，標本数とフィッシャー情報行列の積の逆行列で近似される．同じ行列が，近い予測分布を区別する尺度と，パラメータの推定精度の両方に現れる [3]．

7) 統計科学における情報量規準の文脈では，正則モデルと特異モデルの区別が重要である．正則性を前提に導かれる AIC に対し，WAIC（広く使える情報量規準）は，特異モデルでもベイズ予測の汎化損失を推定できる情報量規準である [2]．

にユークリッド距離の二乗を補う．この補正を damping と呼ぶ．その意味は，2.1.6 項のコラムで説明する．式 (2.8) の KL ダイバージェンスを式 (2.12) で二次近似すると，

$$\boldsymbol{\delta}_k = \underset{\boldsymbol{\delta}}{\operatorname{argmin}} \left\{ \boldsymbol{g}_k^\top \boldsymbol{\delta} + \frac{\lambda}{2} \boldsymbol{\delta}^\top \boldsymbol{F} \boldsymbol{\delta} \right\} \tag{2.13}$$

となる．微分してゼロとおけば $\boldsymbol{g}_k + \lambda \boldsymbol{F} \boldsymbol{\delta}_k = \boldsymbol{0}$ なので，$\eta = 1/\lambda$ を用いて

$$\boldsymbol{\theta}^{(k+1)} = \boldsymbol{\theta}^{(k)} - \eta \boldsymbol{F}^{-1} \nabla \mathcal{L}(\boldsymbol{\theta}^{(k)}) \tag{2.14}$$

を得る．勾配に掛かる $\boldsymbol{F}^{-1}$ を前処理行列，$\boldsymbol{F}^{-1}\nabla\mathcal{L}$ を前処理勾配と呼ぶ．KL ダイバージェンスが大きく増える方向の更新を抑えるため，その曲率を表すフィッシャー情報行列 $\boldsymbol{F}$ の逆行列が掛かる．この更新を自然勾配法と呼ぶ．

$\boldsymbol{F}$ は更新前のパラメータ $\boldsymbol{\theta}^{(k)}$ で計算し，1 回の最小化を行う間は固定する．

2.1.3 損失の二次近似

ここまでは，損失を一次近似し，KL ダイバージェンスを二次近似して更新量を決めた．損失の曲率も使うには，損失の局所モデルにも二次の項を残せばよい．これは，損失を一次近似して得た局所最小化問題の拡張である．損失のヘッセ行列を $\boldsymbol{H} := \nabla^2 \mathcal{L}(\boldsymbol{\theta}^{(k)})$ とおく[8]．このとき，損失の二次近似は

$$\mathcal{L}(\boldsymbol{\theta}^{(k)} + \boldsymbol{\delta}) \approx \mathcal{L}(\boldsymbol{\theta}^{(k)}) + \nabla \mathcal{L}(\boldsymbol{\theta}^{(k)})^\top \boldsymbol{\delta} + \frac{1}{2} \boldsymbol{\delta}^\top \boldsymbol{H} \boldsymbol{\delta} \tag{2.15}$$

となる．近接項には，これまでと同じ $\lambda \boldsymbol{\delta}^\top \boldsymbol{F} \boldsymbol{\delta}/2$ を用いる．損失の近似式にこの近接項を加え，更新量に依存しない定数項を省くと，

$$\begin{aligned} \boldsymbol{\delta}_k &= \underset{\boldsymbol{\delta}}{\operatorname{argmin}} \left\{ \nabla \mathcal{L}(\boldsymbol{\theta}^{(k)})^\top \boldsymbol{\delta} + \frac{1}{2} \boldsymbol{\delta}^\top \boldsymbol{H} \boldsymbol{\delta} + \frac{\lambda}{2} \boldsymbol{\delta}^\top \boldsymbol{F} \boldsymbol{\delta} \right\} \\ &= \underset{\boldsymbol{\delta}}{\operatorname{argmin}} \left\{ \nabla \mathcal{L}(\boldsymbol{\theta}^{(k)})^\top \boldsymbol{\delta} + \frac{1}{2} \boldsymbol{\delta}^\top (\boldsymbol{H} + \lambda \boldsymbol{F}) \boldsymbol{\delta} \right\} \end{aligned} \tag{2.16}$$

を得る．損失の曲率による項と，近接項が加わり，行列 $\boldsymbol{H} + \lambda \boldsymbol{F}$ が現れた．

$\boldsymbol{H} + \lambda \boldsymbol{F}$ が正定値であると仮定する．式 (2.16) を $\boldsymbol{\delta}$ で微分すると，最小解は

$$\nabla \mathcal{L}(\boldsymbol{\theta}^{(k)}) + (\boldsymbol{H} + \lambda \boldsymbol{F}) \boldsymbol{\delta}_k = \boldsymbol{0} \tag{2.17}$$

を満たす．これを解き，$\boldsymbol{\theta}^{(k+1)} = \boldsymbol{\theta}^{(k)} + \boldsymbol{\delta}_k$ に代入すると，

$$\boldsymbol{\theta}^{(k+1)} = \boldsymbol{\theta}^{(k)} - (\boldsymbol{H} + \lambda \boldsymbol{F})^{-1} \nabla \mathcal{L}(\boldsymbol{\theta}^{(k)}) \tag{2.18}$$

となる．この式も，二次近似した問題の最小解を与える式である．$\boldsymbol{H}$ は損失のヘッセ行列，$\boldsymbol{F}$ は KL ダイバージェンスのヘッセ行列であるフィッシャー情報行列である．損失と近接項に由来する二つの行列が加わり，その逆行列が勾配の前処理に使われている．

$\boldsymbol{H}$ が正定値なら，λ をゼロに近づけた極限でニュートン法の更新を得る．$\boldsymbol{H}$ に負の固有値がある場合も，$\boldsymbol{F}$ が正定値なら，λ を十分大きく選ぶことで $\boldsymbol{H} + \lambda \boldsymbol{F}$ を正定値にできる．

8) $\mathcal{L}$ は現在の点の近傍で二階連続微分可能であると仮定する．

2.1.4 Fisher 情報行列と Hessian の関係

損失のヘッセ行列 $\boldsymbol{H}$ と，予測分布の変化を測るフィッシャー情報行列 $\boldsymbol{F}$ は，異なる目的から現れた．しかし，ニューラルネットワークでよく使う損失では，$\boldsymbol{H}$ の Gauss–Newton 近似が $\boldsymbol{F}$ と一致する．その関係を見るため，パラメータから出力への写像と，出力から損失への写像を分けて考える [4, 5].

ネットワークの出力を $\boldsymbol{z} = \boldsymbol{f}_{\boldsymbol{\theta}}(\boldsymbol{x}) \in \mathbb{R}^c$，出力に対する損失を $\ell(y, \boldsymbol{z})$ とし，データの分布 q について

$$\mathcal{L}(\boldsymbol{\theta}) = \mathbb{E}_{(\boldsymbol{x},y)\sim q}[\ell(y, \boldsymbol{f}_{\boldsymbol{\theta}}(\boldsymbol{x}))] \tag{2.19}$$

と書く．q の入力についての周辺分布は，KL 近接項で使う μ と同じものとする．以下では，すべての微分を現在のパラメータ $\boldsymbol{\theta}^{(k)}$ と，それに対応する出力で評価する．出力のヤコビ行列を $\boldsymbol{J}(\boldsymbol{x}) := \partial \boldsymbol{f}_{\boldsymbol{\theta}}(\boldsymbol{x})/\partial \boldsymbol{\theta} \in \mathbb{R}^{c\times d}$，出力に関する損失のヘッセ行列を $\boldsymbol{H}_{\boldsymbol{z}}(y, \boldsymbol{x}) := \nabla^2_{\boldsymbol{z}} \ell(y, \boldsymbol{z})$ と書く．合成関数の微分を二回行うと，パラメータに関するヘッセ行列は

$$\boldsymbol{H} = \underbrace{\mathbb{E}_q[\boldsymbol{J}(\boldsymbol{x})^\top \boldsymbol{H}_{\boldsymbol{z}}(y, \boldsymbol{x}) \boldsymbol{J}(\boldsymbol{x})]}_{\boldsymbol{G}} + \mathbb{E}_q \left[\sum_{a=1}^{c} \frac{\partial \ell}{\partial z_a} \nabla^2_{\boldsymbol{\theta}} f_{\boldsymbol{\theta},a}(\boldsymbol{x}) \right] \tag{2.20}$$

となる[9]．第 1 項は，出力に対する損失の曲率を，ヤコビ行列でパラメータの空間に移したものである．第 2 項には，ネットワークの出力そのものの二階微分が含まれている．

ここで，出力を $\boldsymbol{f}_{\boldsymbol{\theta}^{(k)}+\boldsymbol{\delta}}(\boldsymbol{x}) \approx \boldsymbol{f}_{\boldsymbol{\theta}^{(k)}}(\boldsymbol{x}) + \boldsymbol{J}(\boldsymbol{x})\boldsymbol{\delta}$ と一次近似する．この近似では出力の二階微分がゼロになるため，損失の曲率は式 (2.20) の第 1 項 $\boldsymbol{G}$ で表される．この $\boldsymbol{G}$ を Gauss–Newton 行列と呼び，$\boldsymbol{H}$ を $\boldsymbol{G}$ で置き換えることを Gauss–Newton 近似と呼ぶ[10]．損失が出力 $\boldsymbol{z}$ について凸なら，$\boldsymbol{H}_{\boldsymbol{z}}$ は半正定値なので，$\boldsymbol{G}$ も半正定値になる．ネットワークの非線形性によって $\boldsymbol{H}$ が負の固有値を持つ場合にも，$\boldsymbol{G}$ は近接項と組み合わせやすい曲率の近似になる．

次に，この $\boldsymbol{G}$ をフィッシャー情報行列と比較する．出力 $\boldsymbol{z}$ が予測分布 $p(y \mid \boldsymbol{z})$ を定め，$p_{\boldsymbol{\theta}}(y \mid \boldsymbol{x}) = p(y \mid \boldsymbol{f}_{\boldsymbol{\theta}}(\boldsymbol{x}))$ と書けるとする．出力に関するフィッシャー情報行列を

$$\boldsymbol{F}_{\boldsymbol{z}}(\boldsymbol{x}) := \mathbb{E}_{y\sim p_{\boldsymbol{\theta}^{(k)}}(\cdot\mid\boldsymbol{x})} \left[\nabla_{\boldsymbol{z}} \log p(y \mid \boldsymbol{z}) \nabla_{\boldsymbol{z}} \log p(y \mid \boldsymbol{z})^\top \right] \tag{2.21}$$

とすると，連鎖律から，パラメータに関する行列は

$$\boldsymbol{F} = \mathbb{E}_{\boldsymbol{x}\sim\mu}[\boldsymbol{J}(\boldsymbol{x})^\top \boldsymbol{F}_{\boldsymbol{z}}(\boldsymbol{x}) \boldsymbol{J}(\boldsymbol{x})] \tag{2.22}$$

となる．$\boldsymbol{G}$ と $\boldsymbol{F}$ は，出力の空間で使う曲率がそれぞれ $\boldsymbol{H}_{\boldsymbol{z}}$ と $\boldsymbol{F}_{\boldsymbol{z}}$ であるという違いを持つ．

たとえば，分類モデルの出力 $\boldsymbol{z}$ を logit とし，softmax で得た確率ベクトルを $\boldsymbol{p}$ とする．交差エントロピー損失 $\ell(y, \boldsymbol{z}) = -\log p_y$ を logit で二回微分すると，

$$\boldsymbol{H}_{\boldsymbol{z}}(y, \boldsymbol{x}) = \operatorname{diag}(\boldsymbol{p}) - \boldsymbol{p}\boldsymbol{p}^\top = \boldsymbol{F}_{\boldsymbol{z}}(\boldsymbol{x}) \tag{2.23}$$

9） 微分と分布 q に関する平均を交換できると仮定する．

10） 二乗損失に対するものを Gauss–Newton 近似，一般の損失に対するものを一般化 Gauss–Newton 近似と呼び分けることもある．ここでは両者をまとめて扱う．

を得る．この行列は正解ラベル y に依存しないので，データのラベルで平均してもモデルの予測分布で平均しても同じ行列になる．したがって，この場合には $\boldsymbol{G} = \boldsymbol{F}$ が成り立つ．分散を固定した正規分布の平均をネットワークが出力し，負の対数尤度を二乗損失として使う回帰でも，同じ一致が成り立つ．より一般には，出力を指数型分布の自然パラメータとし，負の対数尤度を損失に選ぶと，出力についてのヘッセ行列がラベルに依存せず，$\boldsymbol{F}_{\boldsymbol{z}}$ と一致する [4]．

この一致により，フィッシャー情報行列は，予測分布の変化を測る行列であると同時に，損失の Gauss–Newton 近似としても理解できる．式 (2.16) でも，$\boldsymbol{H}$ を $\boldsymbol{G} = \boldsymbol{F}$ で近似すれば，曲率と近接項の和は $(1+\lambda)\boldsymbol{F}$ となり，自然勾配と同じ方向の更新が得られる．

2.1.5 指数移動平均での推定

ここまでの更新では，フィッシャー情報行列が得られるとして議論を進めた．実際の学習では，データからこの行列を推定する．式 (2.11) のフィッシャー情報行列は，入力分布 μ と，現在のモデルの予測分布について平均した行列である．μ を入力の真の分布とすれば，現在のミニバッチから計算する行列は，この分布全体での平均に対する標本近似になる．そこで，パラメータの変化が緩やかなときには，ミニバッチごとの推定値を指数移動平均することも，複数のミニバッチを通じてこの平均を近似する方法と捉えられる [6, 7]．指数移動平均は，最近の情報に重みを置きながら，現在の標本だけで決まる前処理を分布全体に基づく前処理へ近づける役割を持つ．

2.1.6 damping の役割

フィッシャー情報行列 $\boldsymbol{F}$ に $\gamma\boldsymbol{I}$ を加える damping には，いくつかの見方がある．ここでは現在の点での $\boldsymbol{F}$ と勾配 $\boldsymbol{g} = \nabla\mathcal{L}(\boldsymbol{\theta})$ を使い，損失を一次近似した場合の更新量

$$\boldsymbol{\delta}_\gamma = -\eta(\boldsymbol{F} + \gamma\boldsymbol{I})^{-1}\boldsymbol{g}, \qquad \gamma > 0 \tag{2.24}$$

について考える．$\boldsymbol{F}$ 自体は，これまでと同じ KL ダイバージェンスのヘッセ行列である．

まず，数値計算の安定性という理由がある．この更新は，連立一次方程式 $(\boldsymbol{F} + \gamma\boldsymbol{I})\boldsymbol{\delta}_\gamma = -\eta\boldsymbol{g}$ を解いて求められる．その際，行列の成分や勾配に含まれる小さな誤差が，解では大きくなることがある．$\boldsymbol{F}$ の最大・最小固有値を $\nu_{\max}, \nu_{\min}$（$\nu_{\min} \geq 0$）とすると，誤差の増幅を評価する 2 ノルムの条件数は

$$\kappa_2(\boldsymbol{F} + \gamma\boldsymbol{I}) = \frac{\nu_{\max} + \gamma}{\nu_{\min} + \gamma} \tag{2.25}$$

である．固有値の比が大きいほど，解が摂動に敏感になる．安定な解法を使っても，丸め誤差による解の相対誤差の上界は，概ねこの条件数と計算精度 $\varepsilon_{\mathrm{mach}}$ の積に比例する [8]．したがって，条件数が大きすぎると，計算結果の精度を保てないことがある．γ を加えると最小固有値も $\nu_{\min} + \gamma$ となり，この誤差増幅を抑えられる．

条件数を $\bar{\kappa} > 1$ 以下にしたいなら，式 (2.25) を解いて

$$\gamma \geq \max\left\{0, \frac{\nu_{\max} - \bar{\kappa}\nu_{\min}}{\bar{\kappa} - 1}\right\} \tag{2.26}$$

とすればよい．許容する $\bar{\kappa}$ は計算精度と要求する解の精度によって変わり，必要な γ は固有値の大きさにも依存する．同じ条件数の行列でも，行列全体を定数倍すれば，必要な γ も同じ定数倍になる．

次に，近接項による正則化としても説明できる．予測分布の変化を測る KL ダイバージェンス D に，パラメータの移動を抑える項を加えて，

$$D_\gamma(\boldsymbol{u}, \boldsymbol{\theta}) := D(\boldsymbol{u}, \boldsymbol{\theta}) + \frac{\gamma}{2}\|\boldsymbol{u} - \boldsymbol{\theta}\|_2^2 \tag{2.27}$$

とする．ここで D は式 (2.10) の入力について平均した KL である．KL の変化が小さくても，パラメータが大きく動けば，第 2 項が増える．この項を加えることで，予測分布の変化とパラメータの移動量の両方を抑える．D を二次近似し，$\lambda = 1/\eta$ を用いれば，局所最小化問題は

$$\boldsymbol{\delta}_\gamma = \operatorname*{argmin}_{\boldsymbol{\delta}} \left\{ \boldsymbol{g}^\top \boldsymbol{\delta} + \frac{1}{2\eta}\boldsymbol{\delta}^\top \boldsymbol{F}\boldsymbol{\delta} + \frac{\gamma}{2\eta}\|\boldsymbol{\delta}\|_2^2 \right\} \tag{2.28}$$

となる．停留条件は $\boldsymbol{g} + \eta^{-1}(\boldsymbol{F} + \gamma \boldsymbol{I})\boldsymbol{\delta}_\gamma = \boldsymbol{0}$ なので，式 (2.24) が得られる．これは更新量に対する二乗ノルムの正則化であり，局所近似を使う範囲を制限する意味も持つ [6].

最後に，damping が小さい固有値方向での勾配ノイズの増幅を抑えることを示す．ここでは現在のパラメータと $\boldsymbol{F}$ を固定し，勾配だけにノイズがある場合を考える．観測する勾配を $\widehat{\boldsymbol{g}} = \boldsymbol{g} + \boldsymbol{\xi}$，$\mathbb{E}[\boldsymbol{\xi}] = \boldsymbol{0}$ とする．$\boldsymbol{F}$ の正規直交固有ベクトルを $\boldsymbol{u}_i$，対応する固有値を $\nu_i \geq 0$ とし，$\xi_i := \boldsymbol{u}_i^\top \boldsymbol{\xi}$ と書けば，その方向の更新量は

$$\boldsymbol{u}_i^\top \widehat{\boldsymbol{\delta}}_\gamma = -\frac{\eta\, \boldsymbol{u}_i^\top \boldsymbol{g}}{\nu_i + \gamma} - \frac{\eta\, \xi_i}{\nu_i + \gamma} \tag{2.29}$$

である．$\mathbb{E}[\xi_i^2] = \sigma_i^2$ とおくと，更新量のこの成分の分散は $\eta^2\sigma_i^2/(\nu_i + \gamma)^2$ となる．$\nu_i > 0$ の方向で damping なしと比べれば，分散は $(\nu_i/(\nu_i + \gamma))^2$ 倍になる．したがって，同じ学習率なら，小さい固有値方向でのノイズの増幅を強く抑えられる．固有値がゼロの方向でも，増幅率は η/γ に抑えられる．

2.2 近接ノルムの一般化

勾配降下法を導いた式 (2.7) では，更新量の大きさをユークリッドノルムで測った．各成分の変化の二乗を足し合わせる代わりに，最も大きく変わる成分を抑えたい場合には，別のノルムを選ぶ方が自然である．また，パラメータが行列なら，その行列が入力に及ぼす作用から更新量の大きさを定めることもできる．

そこで，損失は一次近似したまま，近接項のノルムを一般化して

$$\boldsymbol{\delta}_k \in \operatorname*{argmin}_{\boldsymbol{\delta}} \left\{ \boldsymbol{g}_k^\top \boldsymbol{\delta} + \frac{\lambda}{2}\|\boldsymbol{\delta}\|^2 \right\}, \qquad \lambda > 0 \tag{2.30}$$

を考える．$\boldsymbol{g}_k = \nabla \mathcal{L}(\boldsymbol{\theta}^{(k)})$ と $\boldsymbol{\theta}^{(k+1)} = \boldsymbol{\theta}^{(k)} + \boldsymbol{\delta}_k$ は，これまでと同じである．ここでは最小解の一つを選ぶため，$\in$ を使った．これは式 (2.8) で $D(\boldsymbol{u}, \boldsymbol{\theta}) = \frac{1}{2}\|\boldsymbol{u} - \boldsymbol{\theta}\|^2$ と選ぶことにあたる．以下では，更新量の大きさを固定して方向を求め，その後で大きさを決める [9].

2.2.1 signGD

各成分の変化を同じ上限で抑えるには，最大ノルム $\|\boldsymbol{\delta}\|_\infty := \max_i |\delta_i|$ を使えばよい．$\|\boldsymbol{\delta}\|_\infty \le \rho$ は，すべての成分が $|\delta_i| \le \rho$ を満たすことを意味する．この範囲で損失の一次近似を最も小さくするには，各成分を勾配と逆の符号へ動かせばよい．実際，$g_{k,i}$ を $\boldsymbol{g}_k$ の第 i 成分とすると，

$$\boldsymbol{g}_k^\top \boldsymbol{\delta} = \sum_i g_{k,i}\delta_i \ge -\rho \sum_i |g_{k,i}| = -\rho\|\boldsymbol{g}_k\|_1 \tag{2.31}$$

であり，$\delta_i = -\rho\,\mathrm{sign}(g_{k,i})$ と選べば等号が成り立つ．ここで $\mathrm{sign}(a)$ は，$a>0$ なら 1，$a<0$ なら -1，$a=0$ なら 0 とする．勾配がゼロの成分は，動かしても一次近似の値が変わらないので，更新しないことにした．

$\boldsymbol{g}_k \neq \boldsymbol{0}$ とし，この方向に沿って更新量を決める．式 (2.30) の最小化は，$\rho \ge 0$ について $-\rho\|\boldsymbol{g}_k\|_1 + \lambda\rho^2/2$ を最小化する問題に帰着する．その解は $\rho = \|\boldsymbol{g}_k\|_1/\lambda$ なので，最小解の一つは

$$\boldsymbol{\delta}_k = -\frac{\|\boldsymbol{g}_k\|_1}{\lambda}\,\mathrm{sign}(\boldsymbol{g}_k) \tag{2.32}$$

である．sign はベクトルの各成分に作用させる．ユークリッドノルムを使ったときには勾配に比例する更新が得られたが，最大ノルムでは勾配の符号で方向が決まる．

この方向への更新の大きさを学習率 $\eta > 0$ で指定する方法を，signGD と呼ぶ．更新式は

$$\boldsymbol{\theta}^{(k+1)} = \boldsymbol{\theta}^{(k)} - \eta\,\mathrm{sign}(\boldsymbol{g}_k) \tag{2.33}$$

となる．勾配がゼロでない成分は，勾配の絶対値によらず，同じ大きさ η だけ動く．式 (2.32) との対応は $\lambda = \|\boldsymbol{g}_k\|_1/\eta$ である．前節の勾配降下法では $\eta = 1/\lambda$ とおいたが，符号だけを残した方向を使う場合には，勾配の大きさもこの対応に入る．η を一定に保つなら，近接項の係数 λ を反復ごとに選び直すことになる．$\boldsymbol{g}_k = \boldsymbol{0}$ の場合は，任意の $\lambda > 0$ に対して最小解は $\boldsymbol{\delta}_k = \boldsymbol{0}$ であり，signGD でも更新しない．

2.2.2 SpectralGD と Muon

次に，一つの線形層のパラメータを考える．これまでは全成分をベクトルに並べていたが，ここからは行列の形を保ち，$\boldsymbol{W}_\ell^{(k)} \in \mathbb{R}^{m\times n}$ と書く．以下では層 ℓ を固定し，勾配を $\boldsymbol{g}_k = \nabla_{\boldsymbol{W}_\ell}\mathcal{L}$ と書く．勾配 $\boldsymbol{g}_k$ と更新量 $\boldsymbol{\delta}$ も同じ形の行列とする．記号の意味は変えず，勾配の各成分は $(\boldsymbol{g}_k)_{ij} = \partial\mathcal{L}/\partial(W_\ell)_{ij}$ を現在の点で評価したものとする．ベクトルでの内積に対応するのは，成分ごとの積を足した $\langle \boldsymbol{g}_k, \boldsymbol{\delta}\rangle_{\mathrm{F}} := \mathrm{Tr}(\boldsymbol{g}_k^\top\boldsymbol{\delta})$ であり，損失の一次近似は

$$\mathcal{L}(\boldsymbol{W}_\ell^{(k)} + \boldsymbol{\delta}) \approx \mathcal{L}(\boldsymbol{W}_\ell^{(k)}) + \langle \boldsymbol{g}_k, \boldsymbol{\delta}\rangle_{\mathrm{F}} \tag{2.34}$$

となる．

この層の出力が $\boldsymbol{W}_\ell\boldsymbol{x}$ なら，更新による出力の変化は $\boldsymbol{\delta}\boldsymbol{x}$ である．入力の向きによらず出力の変化を抑えるには，単位長さの入力に対する変化の最大値を測ればよい．それがスペクトルノルム

$$\|\boldsymbol{\delta}\|_{\mathrm{op}} := \max_{\|\boldsymbol{x}\|_2=1} \|\boldsymbol{\delta}\boldsymbol{x}\|_2 \tag{2.35}$$

であり，行列の最大特異値に等しい．この定義から，任意の入力に対して $\|\boldsymbol{\delta x}\|_2 \leq \|\boldsymbol{\delta}\|_{\mathrm{op}}\|\boldsymbol{x}\|_2$ が成り立つ．したがって，このノルムを小さく保つと，入力の大きさに対する出力の変化を抑えられる．

近接項にスペクトルノルムを使い，

$$\boldsymbol{\delta}_k \in \operatorname*{argmin}_{\boldsymbol{\delta}} \left\{ \langle \boldsymbol{g}_k, \boldsymbol{\delta} \rangle_{\mathrm{F}} + \frac{\lambda}{2}\|\boldsymbol{\delta}\|_{\mathrm{op}}^2 \right\} \tag{2.36}$$

を解く．勾配行列がゼロでないとし，その階数を r とする．正の特異値だけを残した特異値分解を $\boldsymbol{g}_k = \boldsymbol{U}_k\boldsymbol{\Sigma}_k\boldsymbol{V}_k^\top$ と書く．$\boldsymbol{U}_k \in \mathbb{R}^{m\times r}$ と $\boldsymbol{V}_k \in \mathbb{R}^{n\times r}$ の列はそれぞれ正規直交し，$\boldsymbol{\Sigma}_k = \mathrm{diag}(\sigma_{k,1}, \ldots, \sigma_{k,r})$ の対角成分は正である．

signGD と同じように，まずノルムを ρ 以下に制限する．$\boldsymbol{U}_k, \boldsymbol{V}_k$ の第 i 列を $\boldsymbol{u}_{k,i}, \boldsymbol{v}_{k,i}$ と書くと，$\|\boldsymbol{\delta}\|_{\mathrm{op}} \leq \rho$ より $\boldsymbol{u}_{k,i}^\top\boldsymbol{\delta}\boldsymbol{v}_{k,i} \geq -\rho$ である．したがって，

$$\langle \boldsymbol{g}_k, \boldsymbol{\delta} \rangle_{\mathrm{F}} = \sum_{i=1}^{r} \sigma_{k,i}\boldsymbol{u}_{k,i}^\top\boldsymbol{\delta}\boldsymbol{v}_{k,i} \geq -\rho\sum_{i=1}^{r}\sigma_{k,i} \tag{2.37}$$

となる．$\boldsymbol{\delta} = -\rho\boldsymbol{U}_k\boldsymbol{V}_k^\top$ と選ぶと，ノルムは ρ で，この不等式の等号が成り立つ．特異値の和を $\|\boldsymbol{g}_k\|_* := \sum_i \sigma_{k,i}$ と書けば，残るのは $-\rho\|\boldsymbol{g}_k\|_* + \lambda\rho^2/2$ の最小化である．よって，式 (2.36) の最小解の一つは

$$\boldsymbol{\delta}_k = -\frac{\|\boldsymbol{g}_k\|_*}{\lambda}\boldsymbol{U}_k\boldsymbol{V}_k^\top \tag{2.38}$$

と求まる．特異値の和 $\|\boldsymbol{g}_k\|_*$ は，核ノルムと呼ばれる．

この方向に学習率 η で進む更新が SpectralGD である．すなわち，

$$\boldsymbol{W}_\ell^{(k+1)} = \boldsymbol{W}_\ell^{(k)} - \eta\boldsymbol{U}_k\boldsymbol{V}_k^\top \tag{2.39}$$

とする．式 (2.38) との対応は $\lambda = \|\boldsymbol{g}_k\|_*/\eta$ である．通常の勾配降下法が $-\eta\boldsymbol{U}_k\boldsymbol{\Sigma}_k\boldsymbol{V}_k^\top$ を加えるのに対し，SpectralGD では正の特異値をすべて 1 に置き換えた方向を使う．signGD が各成分の絶対値をそろえたのに対応して，ここでは特異値方向ごとの更新の大きさをそろえている．階数が不足している場合にも，上の式は最小解の一つを与える．勾配がゼロの特異値方向には更新を加えず，$\boldsymbol{g}_k = \boldsymbol{0}$ なら更新量をゼロとする．

この特異値をそろえる操作を，momentum から作った更新方向に適用する方法が Muon である [10]．現在の勾配だけで方向を決める代わりに，過去の勾配も平均してから，同じ操作を行う．その基本形を，momentum 行列 $\boldsymbol{M}_k$ を用いて表す．初期値を $\boldsymbol{M}_{-1} = \boldsymbol{0}$ とし，$0 \leq \beta < 1$ に対して

$$\boldsymbol{M}_k = \beta\boldsymbol{M}_{k-1} + (1-\beta)\boldsymbol{g}_k \tag{2.40}$$

とする．β が大きいほど，過去の勾配を長く残す．正の特異値だけを残した分解を $\boldsymbol{M}_k = \widetilde{\boldsymbol{U}}_k\widetilde{\boldsymbol{\Sigma}}_k\widetilde{\boldsymbol{V}}_k^\top$ と書くと，直交化を厳密に行う場合の更新は

$$\boldsymbol{W}_\ell^{(k+1)} = \boldsymbol{W}_\ell^{(k)} - \eta\widetilde{\boldsymbol{U}}_k\widetilde{\boldsymbol{V}}_k^\top \tag{2.41}$$

である．$\boldsymbol{M}_k = \boldsymbol{0}$ の場合には更新しない．$\beta = 0$ なら $\boldsymbol{M}_k = \boldsymbol{g}_k$ となり，式 (2.39) の SpectralGD に戻る．つまり，momentum を使わない Muon の基本となる更新方向は，スペクトルノルムを近接項に選ぶことで得られる．

実際の Muon では，特異値分解の代わりに，行列積で計算できる Newton–Schulz 反復を使ってこの操作を近似する．この操作は，基本となる三次の反復で説明できる [9]．一回の更新に使う $\boldsymbol{M}_k \neq \boldsymbol{0}$ を固定し，学習の反復回数 k と区別して，行列計算の反復回数を r と書く．初期値を $\boldsymbol{X}_0 = \boldsymbol{M}_k / \|\boldsymbol{M}_k\|_{\mathrm{F}}$ とし，

$$\boldsymbol{X}_{r+1} = \frac{3}{2}\boldsymbol{X}_r - \frac{1}{2}\boldsymbol{X}_r \boldsymbol{X}_r^{\top} \boldsymbol{X}_r \tag{2.42}$$

を繰り返す．フロベニウスノルムによる規格化で，初期の特異値はすべて 0 以上 1 以下になる．この反復は特異ベクトルを変えず，各特異値に対して

$$\sigma_{r+1} = \frac{3}{2}\sigma_r - \frac{1}{2}\sigma_r^3 \tag{2.43}$$

を適用する．$0 < \sigma_r < 1$ では $\sigma_r < \sigma_{r+1} \leq 1$ となるので，正の特異値は 1 に近づき，ゼロの特異値はゼロのまま残る．したがって，

$$\boldsymbol{X}_r \longrightarrow \widetilde{\boldsymbol{U}}_k \widetilde{\boldsymbol{V}}_k^{\top} =: \mathrm{msign}(\boldsymbol{M}_k) \tag{2.44}$$

となり，Muon の更新方向が得られる．右辺は，特異値に符号関数を適用する意味での行列符号関数であり，極分解の極因子とも呼ばれる [11]．

第 3 章では，AdaGrad の二次統計を近似する問題から，同じ更新方向が現れることを調べる．

2.2.3 Shampoo

SpectralGD では，現在の勾配行列の特異値分解を使って更新方向を決めた．Shampoo は，過去の勾配から二つの行列を作り，勾配行列の左と右から掛けることで前処理する方法である [12]．まず更新式を示し，近接項との対応を確かめた後で，SpectralGD との関係を調べる．

パラメータ，勾配ともに，前項と同じ $m \times n$ の行列とする．ここでは，勾配の二次統計を指数移動平均で推定する．初期値を $\boldsymbol{A}_{-1} = \varepsilon \boldsymbol{I}_m$，$\boldsymbol{B}_{-1} = \varepsilon \boldsymbol{I}_n$ とし，$0 \leq \beta < 1$，$\varepsilon > 0$ に対して，

$$\begin{aligned} \boldsymbol{A}_k &= \beta \boldsymbol{A}_{k-1} + (1-\beta)(\boldsymbol{g}_k \boldsymbol{g}_k^{\top} + \varepsilon \boldsymbol{I}_m), \\ \boldsymbol{B}_k &= \beta \boldsymbol{B}_{k-1} + (1-\beta)(\boldsymbol{g}_k^{\top} \boldsymbol{g}_k + \varepsilon \boldsymbol{I}_n) \end{aligned} \tag{2.45}$$

を定める．$\boldsymbol{A}_k$ は勾配の行同士，$\boldsymbol{B}_k$ は列同士の内積の指数移動平均に，$\varepsilon \boldsymbol{I}$ を加えた行列であり，それぞれ $m \times m$，$n \times n$ の大きさを持つ．β が大きいほど過去の情報を長く残し，$\varepsilon \boldsymbol{I}$ は正定値性を保つために加えている．Shampoo の更新は，これらを用いて

$$\boldsymbol{W}_{\ell}^{(k+1)} = \boldsymbol{W}_{\ell}^{(k)} - \eta \boldsymbol{A}_k^{-1/4} \boldsymbol{g}_k \boldsymbol{B}_k^{-1/4} \tag{2.46}$$

と書ける．行列の $-1/4$ 乗は，正定値行列を固有値分解し，各固有値を $-1/4$ 乗してから同じ固有ベクトルで組み直した行列を意味する．これにより，勾配の二乗の平均が大きい方向ほど更新を抑

える．全成分をベクトルに並べると前処理行列は $mn \times mn$ になるが，Shampoo では左右の二つの行列を保持すればよい．必要な行列要素の数は m^2n^2 から m^2+n^2 に減る．

この更新も，近接項を選ぶことで得られる．1 回の更新の間は $\boldsymbol{A}_k, \boldsymbol{B}_k$ を固定し，更新量を測るノルムを

$$\|\boldsymbol{\delta}\|_k^2 := \mathrm{Tr}\left(\boldsymbol{\delta}^\top \boldsymbol{A}_k^{1/4} \boldsymbol{\delta} \boldsymbol{B}_k^{1/4}\right) = \left\|\boldsymbol{A}_k^{1/8} \boldsymbol{\delta} \boldsymbol{B}_k^{1/8}\right\|_{\mathrm{F}}^2 \tag{2.47}$$

で定める．$\|\boldsymbol{M}\|_{\mathrm{F}}^2 := \sum_{i,j} M_{ij}^2$ はフロベニウスノルムの二乗である．右辺は，行列の左右を変換してから成分の二乗を足すことを表している．両側の変換が可逆なので，これは行列の空間上のノルムを定める．近接項の係数を $\lambda = 1/\eta$ と選ぶと，局所最小化問題は

$$\boldsymbol{\delta}_k = \underset{\boldsymbol{\delta}}{\mathrm{argmin}} \left\{ \langle \boldsymbol{g}_k, \boldsymbol{\delta} \rangle_{\mathrm{F}} + \frac{1}{2\eta} \|\boldsymbol{\delta}\|_k^2 \right\} \tag{2.48}$$

となる．微分してゼロとおくと，

$$\boldsymbol{g}_k + \eta^{-1} \boldsymbol{A}_k^{1/4} \boldsymbol{\delta}_k \boldsymbol{B}_k^{1/4} = \boldsymbol{0} \tag{2.49}$$

を得る．左から $\boldsymbol{A}_k^{-1/4}$，右から $\boldsymbol{B}_k^{-1/4}$ を掛ければ，$\boldsymbol{\delta}_k = -\eta \boldsymbol{A}_k^{-1/4} \boldsymbol{g}_k \boldsymbol{B}_k^{-1/4}$ となり，式 (2.46) が得られた．前節のフィッシャー情報行列は予測分布の変化から定まったが，ここでは観測した勾配の二次統計から近接ノルムを定めている．

では，なぜ左右とも $-1/4$ 乗なのだろうか．SpectralGD との関係を見るために，$\beta = 0$ として現在の勾配だけを使い，$\varepsilon \boldsymbol{I}$ をいったん外して，$\boldsymbol{A}_k = \boldsymbol{g}_k \boldsymbol{g}_k^\top$，$\boldsymbol{B}_k = \boldsymbol{g}_k^\top \boldsymbol{g}_k$ としてみる．この場合は行列が特異になりうるため，以下の負のべき乗では，正の固有値だけをべき乗し，ゼロ固有値はゼロのままにする．これは擬似逆行列を用いることに相当する．前項の特異値分解を代入すると，

$$\begin{aligned}
(\boldsymbol{g}_k \boldsymbol{g}_k^\top)^{-1/4} &= \boldsymbol{U}_k \boldsymbol{\Sigma}_k^{-1/2} \boldsymbol{U}_k^\top, \\
(\boldsymbol{g}_k^\top \boldsymbol{g}_k)^{-1/4} &= \boldsymbol{V}_k \boldsymbol{\Sigma}_k^{-1/2} \boldsymbol{V}_k^\top, \\
(\boldsymbol{g}_k \boldsymbol{g}_k^\top)^{-1/4} \boldsymbol{g}_k (\boldsymbol{g}_k^\top \boldsymbol{g}_k)^{-1/4} &= \boldsymbol{U}_k \boldsymbol{\Sigma}_k^{-1/2} \boldsymbol{\Sigma}_k \boldsymbol{\Sigma}_k^{-1/2} \boldsymbol{V}_k^\top = \boldsymbol{U}_k \boldsymbol{V}_k^\top
\end{aligned} \tag{2.50}$$

となる．勾配の特異値 $\sigma_{k,i}$ に対し，左右からそれぞれ $\sigma_{k,i}^{-1/2}$ が掛かり，積が 1 になる．こうして，過去の履歴と damping を外した Shampoo は，SpectralGD，すなわち momentum を使わず直交化を厳密に行う Muon と同じ更新を与える．

現在の勾配だけを使って $\varepsilon \boldsymbol{I}$ を残すと，更新方向の特異値は $\sigma_{k,i} / \sqrt{\sigma_{k,i}^2 + \varepsilon}$ となり，小さい特異値方向の更新が抑えられる．指数移動平均を用いる Shampoo は，式 (2.47) の近接ノルムを勾配の履歴に応じて変える方法として理解できる．

2.2.4 AdamW との関係

Shampoo は，勾配の二次統計を行列の構造を残して扱う方法だった．同じ二次統計を，成分ごとの二乗だけを残して対角近似すると，Adam の前処理につながる．これに勾配そのものの

指数移動平均を組み合わせたものが Adam である[11]．以下では，パラメータと勾配をベクトル $\boldsymbol{\theta}^{(k)}, \boldsymbol{g}_k \in \mathbb{R}^d$ として書き，AdamW の記法でこの対応を示す．

勾配の平均を $\boldsymbol{m}_k$，勾配の二乗の平均を $\boldsymbol{v}_k$ とし，初期値を $\boldsymbol{m}_{-1} = \boldsymbol{v}_{-1} = \boldsymbol{0}$ とする．$0 \le \beta_1, \beta_2 < 1$ に対して，各反復で

$$\begin{aligned} \boldsymbol{m}_k &= \beta_1 \boldsymbol{m}_{k-1} + (1-\beta_1)\boldsymbol{g}_k, \\ \boldsymbol{v}_k &= \beta_2 \boldsymbol{v}_{k-1} + (1-\beta_2)\boldsymbol{g}_k^{\odot 2} \end{aligned} \tag{2.51}$$

と更新する．$\boldsymbol{g}_k^{\odot 2}$ は各成分を二乗したベクトルである．勾配の外積 $\boldsymbol{g}_k \boldsymbol{g}_k^\top$ の対角成分は $g_{k,i}^2$ なので，$\boldsymbol{v}_k$ は二次統計の対角成分の指数移動平均に当たる．初期値ゼロによる偏りを補正するため，

$$\widehat{\boldsymbol{m}}_k = \frac{\boldsymbol{m}_k}{1-\beta_1^{k+1}}, \qquad \widehat{\boldsymbol{v}}_k = \frac{\boldsymbol{v}_k}{1-\beta_2^{k+1}} \tag{2.52}$$

を使う [13]．

前処理との対応を見るため，$\boldsymbol{D}_k := \operatorname{diag}(\widehat{\boldsymbol{v}}_k)$ とおく．二次統計の対角行列の逆平方根を勾配に掛けることは，各成分を勾配の二乗の平均の平方根で割ることに等しい．近接項を用いると，現在の勾配の代わりにその平均 $\widehat{\boldsymbol{m}}_k$ を使って，

$$\boldsymbol{\delta}_k = \operatorname*{argmin}_{\boldsymbol{\delta}} \left\{ \widehat{\boldsymbol{m}}_k^\top \boldsymbol{\delta} + \frac{1}{2\eta} \boldsymbol{\delta}^\top (\boldsymbol{D}_k^{1/2} + \varepsilon \boldsymbol{I}) \boldsymbol{\delta} \right\}, \qquad \varepsilon > 0 \tag{2.53}$$

と書ける．その最小解は，各成分について $\delta_{k,i} = -\eta \widehat{m}_{k,i} / (\sqrt{\widehat{v}_{k,i}} + \varepsilon)$ となる．勾配の二乗の平均が大きい成分ほど更新を抑える，対角の前処理である．

この更新に，係数 $\lambda_{\mathrm{wd}} \ge 0$ の重み減衰を加えると，AdamW の更新は

$$\boldsymbol{\theta}^{(k+1)} = (1 - \eta\lambda_{\mathrm{wd}})\boldsymbol{\theta}^{(k)} - \eta \frac{\widehat{\boldsymbol{m}}_k}{\sqrt{\widehat{\boldsymbol{v}}_k} + \varepsilon \boldsymbol{1}} \tag{2.54}$$

となる [14]．平方根と割り算は成分ごとに行い，$\boldsymbol{1}$ は全成分が 1 のベクトルである．

最後に，二つの指数移動平均を外して $\beta_1 = \beta_2 = 0$ とし，ε と重み減衰もゼロとする．このとき $\widehat{\boldsymbol{m}}_k = \boldsymbol{g}_k$，$\widehat{\boldsymbol{v}}_k = \boldsymbol{g}_k^{\odot 2}$ なので，

$$\theta_i^{(k+1)} = \theta_i^{(k)} - \eta \frac{g_{k,i}}{\sqrt{g_{k,i}^2}} = \theta_i^{(k)} - \eta \operatorname{sign}(g_{k,i}) \tag{2.55}$$

となり，signGD が得られる [11]．$g_{k,i} = 0$ の成分では更新量をゼロとする．Shampoo から履歴を外すと特異値をそろえる SpectralGD が現れ，Adam から履歴を外すと成分の大きさをそろえる signGD が現れる．どちらも，二次統計の履歴を用いることで，現在の勾配を規格化する更新から，過去の勾配の大きさも反映した更新へ拡張されている．

11） ここで対角近似する対象は，ベクトル化した勾配の二次統計である．Shampoo の左右の行列 $\boldsymbol{A}_k, \boldsymbol{B}_k$ をそれぞれ対角化する場合には，行と列ごとの二次統計を使う更新になる．

第 3 章　AdaGrad

前章では，近接項に使う行列によって，勾配をどのように前処理するかが決まることを見た．この行列を，学習の良し悪しを測る基準から選ぶことはできるだろうか．AdaGrad は，それまでの勾配の二乗を蓄積し，その平方根を使って更新の大きさを調整する方法である．ここでは，学習中の損失をリグレットという量で評価し，その上界を小さくする行列を求めることで，平方根が現れる理由を調べる [15]．その後，AdaGrad が用いる二次統計を小さい行列で近似する問題を考える．前章で導入した Shampoo と Muon を，今度は二次統計の KL 近似として捉え直す．最後に，この二次統計とフィッシャー情報行列の違いを，バッチサイズに注目して調べる．

3.1　リグレットの上界と前処理行列の選び方

3.1.1　リグレット

データが一つずつ与えられ，そのたびにパラメータを更新する学習を考える．時刻 t には，それまでのデータから選んだパラメータ $\boldsymbol{\theta}^{(t)} \in \mathbb{R}^d$ で予測し，その後で今回のデータに対する損失 $\mathcal{L}_t$ と勾配 $\boldsymbol{g}_t = \nabla \mathcal{L}_t(\boldsymbol{\theta}^{(t)})$ を知る．この勾配を使って $\boldsymbol{\theta}^{(t+1)}$ を決める．この設定をオンライン学習と呼ぶ．たとえば，各時刻に異なる訓練例を使うとき，$\mathcal{L}_t$ はその訓練例での損失である．

学習の良し悪しを測るために，すべての時刻で同じパラメータ $\boldsymbol{\theta}^*$ を使った場合と比べる．両者の累積損失の差

$$\mathcal{R}_T(\boldsymbol{\theta}^*) := \sum_{t=1}^{T} \mathcal{L}_t(\boldsymbol{\theta}^{(t)}) - \sum_{t=1}^{T} \mathcal{L}_t(\boldsymbol{\theta}^*) \tag{3.1}$$

を，$\boldsymbol{\theta}^*$ に対するリグレット（regret）という．比較相手には，あとから全データを見て累積損失を最小にするパラメータを選んでよい．その最小解が存在するなら，$\boldsymbol{\theta}^* \in \operatorname{argmin}_{\boldsymbol{u}} \sum_{t=1}^{T} \mathcal{L}_t(\boldsymbol{u})$ とする．リグレットの上界が T より遅く増えれば，1 回あたりの損失差の上界はゼロに近づく．未来を知らずに更新しても，固定した比較相手に対する平均の不利を小さくできる，という評価である．

3.1.2　リグレットの上界から AdaGrad を導く

以下では，各 $\mathcal{L}_t$ が微分可能な凸関数であると仮定する．凸性から，任意の比較相手 $\boldsymbol{\theta}^*$ について

$$\mathcal{L}_t(\boldsymbol{\theta}^{(t)}) - \mathcal{L}_t(\boldsymbol{\theta}^*) \le \boldsymbol{g}_t^\top (\boldsymbol{\theta}^{(t)} - \boldsymbol{\theta}^*) \tag{3.2}$$

が成り立つ．これは，凸関数のグラフがその接平面より下には来ないことを，$\boldsymbol{\theta}^*$ で評価した式である．したがって，右辺を足し合わせた量を抑えれば，リグレットも抑えられる．

まず，正定値対称行列 $\boldsymbol{G}$ を学習中ずっと固定し，学習率 $\eta > 0$ で

$$\boldsymbol{\theta}^{(t+1)} = \boldsymbol{\theta}^{(t)} - \eta \boldsymbol{G}^{-1} \boldsymbol{g}_t \tag{3.3}$$

と更新する場合を調べる．ここで $\boldsymbol{G}$ は近接項の行列であり，勾配に掛かる前処理行列は $\boldsymbol{G}^{-1}$ である．前章の自然勾配法ではフィッシャー情報行列 $\boldsymbol{F}$ を用いたが，ここでは $\boldsymbol{G}$ を勾配列から選ぶ．この更新は，$\boldsymbol{g}_t^\top \boldsymbol{\delta} + \boldsymbol{\delta}^\top \boldsymbol{G} \boldsymbol{\delta}/(2\eta)$ を最小にする更新量を選んでいる．

比較相手までの距離が 1 回の更新でどう変わるかを計算する．$\|\boldsymbol{v}\|_{\boldsymbol{G}}^2 := \boldsymbol{v}^\top \boldsymbol{G} \boldsymbol{v}$ と書くと，更新式を代入して

$$\begin{aligned} \|\boldsymbol{\theta}^{(t+1)} - \boldsymbol{\theta}^*\|_{\boldsymbol{G}}^2 = \|\boldsymbol{\theta}^{(t)} - \boldsymbol{\theta}^*\|_{\boldsymbol{G}}^2 - 2\eta \boldsymbol{g}_t^\top (\boldsymbol{\theta}^{(t)} - \boldsymbol{\theta}^*) \\ + \eta^2 \boldsymbol{g}_t^\top \boldsymbol{G}^{-1} \boldsymbol{g}_t \end{aligned} \tag{3.4}$$

を得る．第 2 項を左辺に移せば，式 (3.2) の右辺を，更新前後の距離の差で表せる．これを $t = 1, \ldots, T$ について足すと，途中の時刻の距離は相殺される．最後の距離の項は非正なので省くことができ，

$$\mathcal{R}_T(\boldsymbol{\theta}^*) \le \frac{1}{2\eta} \|\boldsymbol{\theta}^{(1)} - \boldsymbol{\theta}^*\|_{\boldsymbol{G}}^2 + \frac{\eta}{2} \sum_{t=1}^{T} \boldsymbol{g}_t^\top \boldsymbol{G}^{-1} \boldsymbol{g}_t \tag{3.5}$$

となる．第 1 項は初期値から比較相手までの距離，第 2 項は学習中に得られた勾配による寄与である．

この上界を，行列 $\boldsymbol{G}$ を選びやすい形に整理する．勾配の外積を足した行列を $\boldsymbol{V}_T := \sum_{t=1}^{T} \boldsymbol{g}_t \boldsymbol{g}_t^\top$ とおく．その対角成分は各座標の勾配の二乗和，非対角成分は異なる座標の勾配の積の和である．これは勾配の二次統計を累積した行列である．行列の対角成分の和を Tr で表すと，$\sum_t \boldsymbol{g}_t^\top \boldsymbol{G}^{-1} \boldsymbol{g}_t = \mathrm{Tr}(\boldsymbol{G}^{-1} \boldsymbol{V}_T)$ と書ける．また，$D > 0$ を $\|\boldsymbol{\theta}^{(1)} - \boldsymbol{\theta}^*\|_2 \le D$ を満たす定数とする．$\boldsymbol{G}$ の最大固有値は正の固有値の和 $\mathrm{Tr}(\boldsymbol{G})$ 以下だから，$\|\boldsymbol{\theta}^{(1)} - \boldsymbol{\theta}^*\|_{\boldsymbol{G}}^2 \le D^2 \,\mathrm{Tr}(\boldsymbol{G})$ である．したがって，

$$\mathcal{R}_T(\boldsymbol{\theta}^*) \le \frac{D^2}{2\eta} \,\mathrm{Tr}(\boldsymbol{G}) + \frac{\eta}{2} \,\mathrm{Tr}(\boldsymbol{G}^{-1} \boldsymbol{V}_T) =: F(\boldsymbol{G}) \tag{3.6}$$

を得る．$\boldsymbol{G}$ を定数倍して大きくすれば，更新は小さくなり，第 2 項は減るが，第 1 項は増える．二つの項の釣り合いを考えて，$\boldsymbol{G}$ を選ぶ必要がある．

そこで，観測した勾配列を固定し，その上界 $F(\boldsymbol{G})$ を最小にする正定値対称行列を求める．まず $\boldsymbol{V}_T$ が正定値の場合を考える．逆行列の微分 $d(\boldsymbol{G}^{-1}) = -\boldsymbol{G}^{-1} (d\boldsymbol{G}) \boldsymbol{G}^{-1}$ とトレースの巡回性を使うと，

$$dF = \mathrm{Tr}\left[\left(\frac{D^2}{2\eta} \boldsymbol{I} - \frac{\eta}{2} \boldsymbol{G}^{-1} \boldsymbol{V}_T \boldsymbol{G}^{-1} \right) d\boldsymbol{G} \right]$$

となる．任意の対称な変化 $d\boldsymbol{G}$ に対してこれがゼロになる条件は，

$$\boldsymbol{G}^{-1} \boldsymbol{V}_T \boldsymbol{G}^{-1} = \frac{D^2}{\eta^2} \boldsymbol{I} \tag{3.7}$$

である．両側から $\boldsymbol{G}$ を掛ければ $\boldsymbol{V}_T = (D^2/\eta^2) \boldsymbol{G}^2$ なので，

$$\boldsymbol{G}_* = \frac{\eta}{D} \boldsymbol{V}_T^{1/2}, \qquad F(\boldsymbol{G}_*) = D \,\mathrm{Tr}(\boldsymbol{V}_T^{1/2}) \tag{3.8}$$

と求まる．$\boldsymbol{V}_T^{1/2}$ は，$\boldsymbol{V}_T$ を固有値分解し，各固有値を正の平方根に置き換えた行列である．F は正定値対称行列上の凸関数なので，この停留条件を満たす $\boldsymbol{G}_*$ は最小解である．平方根は，上界を最小にする条件を解く過程で現れた．

Duchi らは，行列の大きさを $\mathrm{Tr}(\boldsymbol{G}) \le c$（$c > 0$）で制限し，$\mathrm{Tr}(\boldsymbol{G}^{-1}\boldsymbol{V}_T)$ を最小にする問題としても，この選択を説明している．その解は $\boldsymbol{G}_* = c\boldsymbol{V}_T^{1/2} / \mathrm{Tr}(\boldsymbol{V}_T^{1/2})$ であり，行列の形は同じである．全体の定数倍は学習率に吸収できるので，前処理の形として得られたのは $\boldsymbol{V}_T^{-1/2}$ である．

この行列による勾配の変換は，次のように解釈できる．式 (3.7) の左辺を展開すると，

$$\sum_{t=1}^{T} (\boldsymbol{G}_*^{-1}\boldsymbol{g}_t)(\boldsymbol{G}_*^{-1}\boldsymbol{g}_t)^\top = \frac{D^2}{\eta^2}\boldsymbol{I} \tag{3.9}$$

となる．任意の単位ベクトル $\boldsymbol{u}$ を両側から掛ければ，$\sum_t (\boldsymbol{u}^\top \boldsymbol{G}_*^{-1}\boldsymbol{g}_t)^2 = D^2/\eta^2$ である．つまり，過去の勾配をすべて同じ $\boldsymbol{G}_*^{-1}$ で変換すると，どの方向に射影しても二乗和が等しくなる．これを累積二次統計の等方化と呼ぶ．

オンライン学習では，時刻 t までの勾配から $\boldsymbol{V}_t = \sum_{s=1}^{t} \boldsymbol{g}_s \boldsymbol{g}_s^\top$ を計算し，その平方根で近接項を逐次更新する．すなわち，

$$\boldsymbol{G}_t = \boldsymbol{V}_t^{1/2} + \varepsilon \boldsymbol{I}, \qquad \boldsymbol{\theta}^{(t+1)} = \boldsymbol{\theta}^{(t)} - \eta \boldsymbol{G}_t^{-1}\boldsymbol{g}_t, \quad \varepsilon > 0 \tag{3.10}$$

とする．これが行列全体を用いる AdaGrad（full-matrix AdaGrad）である．現在の勾配 $\boldsymbol{g}_t$ も蓄積してから，次のパラメータを求める．初期の $\boldsymbol{V}_t$ は一般に特異なので，$\varepsilon\boldsymbol{I}$ を加えて逆行列を定義できるようにしている．

逐次更新のリグレットを評価するには，式 (3.4) を足し合わせ，行列の変化に由来する距離の項も評価する．$\boldsymbol{G}_t - \boldsymbol{G}_{t-1}$ の半正定値性を使うと，この項を抑えられる．初期値だけでなく全時刻で $\|\boldsymbol{\theta}^{(t)} - \boldsymbol{\theta}^*\|_2 \le D$ と仮定すれば，その寄与は $D^2 \,\mathrm{Tr}(\boldsymbol{G}_T)/(2\eta)$ 以下となる．さらに $\sum_{t=1}^{T} \boldsymbol{g}_t^\top \boldsymbol{G}_t^{-1}\boldsymbol{g}_t \le 2\,\mathrm{Tr}(\boldsymbol{V}_T^{1/2})$ を用いると，

$$\mathcal{R}_T(\boldsymbol{\theta}^*) \le \left(\frac{D^2}{2\eta} + \eta\right) \mathrm{Tr}(\boldsymbol{V}_T^{1/2}) + \frac{\varepsilon d D^2}{2\eta} \tag{3.11}$$

を得る [15][1)]．このように，逐次更新する場合にも，事後的な最小値に現れた $\mathrm{Tr}(\boldsymbol{V}_T^{1/2})$ でリグレットを抑えられる．たとえば勾配の長さが $\|\boldsymbol{g}_t\|_2 \le K$ に抑えられていれば，$\mathrm{Tr}(\boldsymbol{V}_T^{1/2}) \le \sqrt{d\,\mathrm{Tr}(\boldsymbol{V}_T)} \le K\sqrt{dT}$ である．$D, K, d, \eta, \varepsilon$ が T に依存しなければ，上界は $O(\sqrt{T})$ で増え，1 回あたりの損失差の上界はゼロに近づく．

最後に，通常よく使われる，座標ごとの AdaGrad を同じ考え方で導く．行列全体を蓄積すると d^2 個の成分を持つ必要があるため，$\boldsymbol{G}$ を対角行列 $\mathrm{diag}(a_1, \ldots, a_d)$（$a_i > 0$）に制限する．この場合，式 (3.6) の上界は

$$F(\boldsymbol{G}) = \sum_{i=1}^{d} \left\{ \frac{D^2}{2\eta} a_i + \frac{\eta}{2a_i} \sum_{t=1}^{T} g_{t,i}^2 \right\} \tag{3.12}$$

1) ここでは，距離に由来する項をトレースで評価した，やや緩い上界を記した．

となり，座標ごとに最小化できる．各座標の二乗和が正なら，微分してゼロとおくことで $D^2/(2\eta) - \eta \sum_t g_{t,i}^2/(2a_i^2) = 0$，したがって $a_i = (\eta/D)\sqrt{\sum_t g_{t,i}^2}$ を得る．ここでも二乗和の平方根が現れる．時刻 t までの二乗和 $v_{t,i} := \sum_{s=1}^{t} g_{s,i}^2$ を使い，先ほどと同様に $\varepsilon > 0$ を加えると，更新は

$$\theta_i^{(t+1)} = \theta_i^{(t)} - \frac{\eta}{\sqrt{v_{t,i}} + \varepsilon}\, g_{t,i}, \qquad i = 1, \ldots, d \tag{3.13}$$

となる．これが対角版の AdaGrad である[2)]．勾配の二乗が多く蓄積した座標ほど，同じ勾配に対する更新が小さくなる．各座標の二乗和だけを保存すればよいので，必要な記憶量は $O(d)$ である．対角版が調整するのは，各座標の勾配の二乗和である．近接項にどこまで自由な行列を使うかによって，計算量と，勾配の方向ごとの差を調整できる範囲が変わるのである．

3.2 KL 最小化から one-sided Shampoo と Muon へ

行列全体を使う AdaGrad では，$\boldsymbol{V}_t = \sum_{s=1}^{t} \boldsymbol{g}_s \boldsymbol{g}_s^\top$ を蓄積し，その逆平方根を勾配に掛けた．パラメータが多いと，この行列を保持し，逆平方根を求める計算が難しくなる．対角版はその一つの解決策だが，座標間の関係をすべて省いてしまう．前章の Shampoo のように，パラメータの行列としての形を利用して，より多くの関係を残すことはできるだろうか．

ここでは，$\boldsymbol{V}_t$ を計算しやすい構造の行列で近似し，近似した行列の逆平方根を使う．その近似の良し悪しを KL ダイバージェンスで測ると，one-sided Shampoo が最適解として得られる [17]．本節では，論文の期待値による二次統計を，前節の AdaGrad に合わせて勾配外積の累積和で表す．この片側近似から，前章で導入した Muon の更新方向も得られる．近接ノルムの選択として見た更新を，ここでは AdaGrad の二次統計の近似として捉え直す．

3.2.1 one-sided Shampoo の導出

前章と同じように，一つの層のパラメータを $\boldsymbol{W}_\ell \in \mathbb{R}^{m \times n}$ とし，以下では層 ℓ を固定し，勾配 $\boldsymbol{g}_s$ も $m \times n$ の行列として扱う．行列を列ごとに縦に並べる操作を vec と書くと，前節の累積行列は

$$\boldsymbol{V}_t = \sum_{s=1}^{t} \operatorname{vec}(\boldsymbol{g}_s) \operatorname{vec}(\boldsymbol{g}_s)^\top \tag{3.14}$$

であり，大きさは $mn \times mn$ である．以下では時刻 t と観測済みの勾配列を固定し，この行列をどう近似するかを考える．

二つの正定値行列の違いを測るために，それぞれを共分散とする平均ゼロのガウス分布を用意する．まず，$\widetilde{\boldsymbol{V}}_t := \boldsymbol{V}_t + \kappa \boldsymbol{I}_{mn}$（$\kappa > 0$）として正定値性を保ち，近似する側の正定値行列を $\boldsymbol{S}$ とする．また，前章の KL はモデルの予測分布間の違いを測ったが，ここでは勾配の二次統計を表す行列間の違いを測る．

---

2) RMSProp[16] は，勾配の二乗の累積和を指数移動平均 $v_{t,i} = \beta v_{t-1,i} + (1-\beta) g_{t,i}^2$（$0 < \beta < 1$）に置き換える．これにより，古い勾配の寄与を減衰させ，最近の勾配の大きさに応じて更新量を調整する．Adam[13] は，勾配の二乗に加えて勾配そのものの指数移動平均も使う．両方の平均について初期値ゼロに由来する偏りを補正し，勾配の平均を勾配の二乗の平均の平方根で割って更新する．

連続分布の KL は，密度 p, q に対して $D_{\mathrm{KL}}(p\|q) = \int p(\boldsymbol{z}) \log(p(\boldsymbol{z})/q(\boldsymbol{z}))\, d\boldsymbol{z}$ と定める．ガウス密度の対数を代入し，$\mathbb{E}[\boldsymbol{z}\boldsymbol{z}^\top] = \widetilde{\boldsymbol{V}}_t$ を用いると，

$$\begin{aligned}\mathcal{D}_t(\boldsymbol{S}) &:= D_{\mathrm{KL}}\Big(\mathcal{N}(\boldsymbol{0}, \widetilde{\boldsymbol{V}}_t) \,\Big\|\, \mathcal{N}(\boldsymbol{0}, \boldsymbol{S})\Big) \\ &= \frac{1}{2}\Big\{\mathrm{Tr}(\boldsymbol{S}^{-1}\widetilde{\boldsymbol{V}}_t) + \log\det \boldsymbol{S} - \log\det \widetilde{\boldsymbol{V}}_t - mn\Big\} \end{aligned} \tag{3.15}$$

を得る．構造を制限しなければ，$\boldsymbol{S} = \widetilde{\boldsymbol{V}}_t$ で KL はゼロになり，これが最小解である．その逆平方根を使うと，damping を加えた行列全体の AdaGrad に戻る[3)]．

次に，左から掛ける $m \times m$ の行列だけを使う，という制約を加える．そのために $\boldsymbol{S} = \boldsymbol{I}_n \otimes \boldsymbol{A}$ と選ぶ．$\otimes$ はクロネッカー積であり，ここでは対角ブロックに正定値行列 $\boldsymbol{A}$ を n 個並べた行列を表す．この構造なら，

$$(\boldsymbol{I}_n \otimes \boldsymbol{A})^{-1/2}\,\mathrm{vec}(\boldsymbol{g}_t) = \mathrm{vec}(\boldsymbol{A}^{-1/2}\boldsymbol{g}_t) \tag{3.16}$$

となり，勾配行列の各列に同じ $\boldsymbol{A}^{-1/2}$ を左から掛ければよい．列同士の二次統計を省く一方で，各列の中の行方向の関係は残している．

この制約のもとで KL を最小にする $\boldsymbol{A}$ を求める．対角ブロックが n 個あるので $\log\det(\boldsymbol{I}_n \otimes \boldsymbol{A}) = n \log\det \boldsymbol{A}$ である．また，トレースの項は

$$\begin{aligned}\mathrm{Tr}\Big[(\boldsymbol{I}_n \otimes \boldsymbol{A})^{-1}\widetilde{\boldsymbol{V}}_t\Big] &= \sum_{s=1}^{t} \mathrm{Tr}(\boldsymbol{g}_s^\top \boldsymbol{A}^{-1}\boldsymbol{g}_s) + n\kappa\,\mathrm{Tr}(\boldsymbol{A}^{-1}) \\ &= \mathrm{Tr}\left[\boldsymbol{A}^{-1}\left(\sum_{s=1}^{t}\boldsymbol{g}_s\boldsymbol{g}_s^\top + n\kappa\boldsymbol{I}_m\right)\right] \end{aligned} \tag{3.17}$$

となる．$\boldsymbol{A}$ に依存しない項を省くと，最小化する式は

$$\frac{n}{2}\log\det\boldsymbol{A} + \frac{1}{2}\,\mathrm{Tr}\left[\boldsymbol{A}^{-1}\left(\sum_{s=1}^{t}\boldsymbol{g}_s\boldsymbol{g}_s^\top + n\kappa\boldsymbol{I}_m\right)\right] \tag{3.18}$$

である．逆行列 $\boldsymbol{P} := \boldsymbol{A}^{-1}$ を変数にすると，第 1 項は $-(n/2)\log\det\boldsymbol{P}$，第 2 項は $\boldsymbol{P}$ の一次式になる．微分してゼロとおく条件は

$$-n\boldsymbol{P}^{-1} + \sum_{s=1}^{t}\boldsymbol{g}_s\boldsymbol{g}_s^\top + n\kappa\boldsymbol{I}_m = \boldsymbol{0} \tag{3.19}$$

なので，

$$\boldsymbol{A}_t^* = \frac{1}{n}\sum_{s=1}^{t}\boldsymbol{g}_s\boldsymbol{g}_s^\top + \kappa\boldsymbol{I}_m \tag{3.20}$$

を得る．$-\log\det\boldsymbol{P}$ は正定値行列上で狭義凸だから，これは唯一の最小解である．大きな $\boldsymbol{V}_t$ を実際に作らなくても，行方向の積を蓄積するだけで最適な近似を求められた．

---

3) ここでは二次統計に $\kappa\boldsymbol{I}$ を加えてから逆平方根を取る．前節の式 (3.10) では平方根の外に $\varepsilon\boldsymbol{I}$ を加えた．有限の damping では異なる更新だが，$\boldsymbol{V}_t$ が正定値なら，どちらも damping をゼロにした極限で $\boldsymbol{V}_t^{-1/2}$ になる．

この近似行列の逆平方根を使えば，更新は

$$\boldsymbol{W}_\ell^{(t+1)} = \boldsymbol{W}_\ell^{(t)} - \eta(\boldsymbol{A}_t^*)^{-1/2}\boldsymbol{g}_t \tag{3.21}$$

となる．これが，左側だけを使う one-sided Shampoo である．前章の Shampoo は左右に $-1/4$ 乗を掛けたが，ここでは片側に $-1/2$ 乗を掛ける．右側だけを使う場合も，同じ計算から $\boldsymbol{B}_t^* = m^{-1}\sum_{s=1}^t \boldsymbol{g}_s^\top \boldsymbol{g}_s + \kappa \boldsymbol{I}_n$ を得て，更新方向を $\boldsymbol{g}_t(\boldsymbol{B}_t^*)^{-1/2}$ とすればよい．係数 $1/n$，$1/m$ は KL の最小化から決まり，元の勾配行列の形に依存している．

3.2.2 Muon との関係

前章では，スペクトルノルムから得た更新方向を用いて Muon を導入した．ここでは，同じ方向が one-sided Shampoo の KL 最適解から現れることを確かめる．現在の勾配だけで同じ KL 近似を行うと，どのような更新になるだろうか．履歴を外し，近似の対象を $\mathrm{vec}(\boldsymbol{g}_t)\,\mathrm{vec}(\boldsymbol{g}_t)^\top + \kappa \boldsymbol{I}_{mn}$ とする．まず $m \le n$ の場合に，行列の小さい側にあたる左側を使う．式 (3.20) は $\boldsymbol{A}_t^* = \boldsymbol{g}_t\boldsymbol{g}_t^\top/n + \kappa \boldsymbol{I}_m$ となる．

前章と同じように，正の特異値だけを残した分解を $\boldsymbol{g}_t = \boldsymbol{U}_t\boldsymbol{\Sigma}_t\boldsymbol{Q}_t^\top$ と書く．累積行列 $\boldsymbol{V}_t$ と区別するため，右特異ベクトルを並べた行列は $\boldsymbol{Q}_t$ とした．特異値を $\sigma_{t,i} > 0$ とすると，

$$(\boldsymbol{A}_t^*)^{-1/2}\boldsymbol{g}_t = \boldsymbol{U}_t\,\mathrm{diag}\left(\frac{\sigma_{t,i}}{\sqrt{\sigma_{t,i}^2/n + \kappa}}\right)\boldsymbol{Q}_t^\top \xrightarrow[\kappa\downarrow 0]{} \sqrt{n}\,\boldsymbol{U}_t\boldsymbol{Q}_t^\top \tag{3.22}$$

となる．$m > n$ なら右側を使い，同じ計算で $\sqrt{m}\,\boldsymbol{U}_t\boldsymbol{Q}_t^\top$ を得る．したがって，小さい側を使う one-sided Shampoo のこの極限は，

$$\boldsymbol{W}_\ell^{(t+1)} = \boldsymbol{W}_\ell^{(t)} - \eta\sqrt{\max(m,n)}\,\boldsymbol{U}_t\boldsymbol{Q}_t^\top \tag{3.23}$$

と書ける．これは，momentum を使わない Muon の更新方向に，行列の形から決まる係数を掛けたものである．特異値を 1 にそろえる方向は，前章で示した momentum なしの Muon と同じである．一つの行列だけを扱うなら $\sqrt{\max(m,n)}$ を学習率に吸収できるが，形の異なる層に共通の学習率を使う場合には，層ごとの更新量を変える係数として残る．

現在の勾配の外積は高々階数 1 であり，$mn > 1$ では特異になる．$\kappa > 0$ で KL 最小化を行ってから極限を取れば，階数不足の場合も更新方向を定義できる．負のべき乗を擬似逆行列の意味で使えば，同じ極限を直接表せる．ゼロの特異値方向には更新を加えず，$\boldsymbol{g}_t = \boldsymbol{0}$ なら更新しない．

この意味で，Muon の基本となる行列の直交化は，AdaGrad の二次統計を片側構造で KL 最小化した結果として理解できる．履歴の使い方は，one-sided Shampoo では勾配外積の蓄積，Muon では momentum 行列の直交化である．

両側を使う場合にも，KL によって近似を選べる．今度は $\boldsymbol{S} = \boldsymbol{B} \otimes \boldsymbol{A}$ として，正定値の $\boldsymbol{A}, \boldsymbol{B}$ を両方とも変える．式を簡単にするため，$\boldsymbol{V}_t$ が正定値で $\kappa = 0$ の場合を考えると，最適解が満たす条件は

$$\boldsymbol{A}^* = \frac{1}{n}\sum_{s=1}^t \boldsymbol{g}_s(\boldsymbol{B}^*)^{-1}\boldsymbol{g}_s^\top, \qquad \boldsymbol{B}^* = \frac{1}{m}\sum_{s=1}^t \boldsymbol{g}_s^\top(\boldsymbol{A}^*)^{-1}\boldsymbol{g}_s \tag{3.24}$$

となる．左右の行列は，互いの逆行列を使って定まる．この条件を満たす理想化した two-sided の KL-Shampoo では，更新方向は $(\boldsymbol{A}^*)^{-1/2}\boldsymbol{g}_t(\boldsymbol{B}^*)^{-1/2}$ である．前章の通常の Shampoo では，左右の積をそれぞれ独立に蓄積し，$-1/4$ 乗を使う．

3.2.3 Shampoo の指数と左右の行列の作り方

前項で得た two-sided の KL-Shampoo は，左右の行列の $-1/2$ 乗で勾配を前処理する．一方，第 2 章で紹介した通常の Shampoo は $-1/4$ 乗を使う．この指数の違いを，左右の行列の作り方と合わせて調べる．まず，通常の Shampoo から勾配の履歴と damping を外し，指数を $-p$（$p > 0$）とする．前項と同じ記号で $\boldsymbol{g}_t = \boldsymbol{U}_t\boldsymbol{\Sigma}_t\boldsymbol{Q}_t^\top$ と書くと，

$$(\boldsymbol{g}_t\boldsymbol{g}_t^\top)^{-p}\boldsymbol{g}_t(\boldsymbol{g}_t^\top\boldsymbol{g}_t)^{-p} = \boldsymbol{U}_t\boldsymbol{\Sigma}_t^{1-4p}\boldsymbol{Q}_t^\top \tag{3.25}$$

となる．$p = 1/4$ なら正の特異値がすべて 1 になり，SpectralGD の方向を得る．$p = 1/2$ なら，特異値は $\sigma_{t,i}^{-1}$ となり，もとの特異値が小さい方向ほど大きく更新する．

一方，左右の行列の作り方を変えると，$p = 1/2$ でも SpectralGD の方向が得られる．これを示したのが，Eschenhagen らの Proposition 4.8 である [11]．同論文の KL-Shampoo では，左の行列を作るときに右の逆行列を，右の行列を作るときに左の逆行列を使う．その働きを見るため，勾配を一つの行列 $\boldsymbol{g} \in \mathbb{R}^{m\times n}$ に固定し，左右の行列だけを反復して更新する．以下の s は，この内側の反復の回数を表す．次元の係数を付けない同論文の反復を用い，初期値を $\boldsymbol{A}_0 = c\boldsymbol{I}_m$，$\boldsymbol{B}_0 = c\boldsymbol{I}_n$（$c > 0$）とする．$0 < \beta < 1$ に対して

$$\begin{aligned}\boldsymbol{A}_{s+1} &= \beta\boldsymbol{A}_s + (1-\beta)\boldsymbol{g}\boldsymbol{B}_s^{-1}\boldsymbol{g}^\top,\\ \boldsymbol{B}_{s+1} &= \beta\boldsymbol{B}_s + (1-\beta)\boldsymbol{g}^\top\boldsymbol{A}_s^{-1}\boldsymbol{g}\end{aligned} \tag{3.26}$$

とする．通常の Shampoo では左右の積を独立に蓄積したが，ここでは相手側の行列で前処理してから積を取っている．

この反復で各特異値方向に何が起こるかを調べる．正の特異値だけを残した分解を $\boldsymbol{g} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{Q}^\top$ と書き，その階数を r とする．初期値が単位行列の定数倍なので，$\boldsymbol{U}$，$\boldsymbol{Q}$ の基底では，左右の行列はそれぞれ対角のまま変化する．対応する第 i 成分は同じ初期値から同じ式で更新されるので，共通の値を $a_{s,i}$ と書くと，

$$a_{s+1,i} = \beta a_{s,i} + (1-\beta)\frac{\sigma_i^2}{a_{s,i}}, \qquad a_{0,i} = c, \qquad i = 1,\dots,r \tag{3.27}$$

となる．この式の正の固定点は $a_i = \sigma_i$ である．とくに $\beta = 1/2$ なら，$a_{s+1,i} = (a_{s,i} + \sigma_i^2/a_{s,i})/2$ となり，平方根 $\sqrt{\sigma_i^2}$ を求めるニュートン法そのものである．

一般の $0 < \beta < 1$ でも，この反復は σ_i に収束する．実際，$z_s := \log(a_{s,i}/\sigma_i)$ とおくと，$z_{s+1} = \log(\beta e^{z_s} + (1-\beta)e^{-z_s})$ である．$z_s \neq 0$ なら，対数の中の値は $e^{-|z_s|}$ と $e^{|z_s|}$ の間にあるため，$|z_{s+1}| < |z_s|$ となる．写像の連続性と合わせると，$|z_s|$ の極限はゼロであり，$a_{s,i} \to \sigma_i$ を得る．また，勾配がゼロの特異値方向では，左右の行列の固有値は $c\beta^s$ でゼロに近づく．したがって，行

列としての極限は

$$\boldsymbol{A}_\infty = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{U}^\top = (\boldsymbol{g}\boldsymbol{g}^\top)^{1/2}, \qquad \boldsymbol{B}_\infty = \boldsymbol{Q}\boldsymbol{\Sigma}\boldsymbol{Q}^\top = (\boldsymbol{g}^\top\boldsymbol{g})^{1/2} \tag{3.28}$$

となる．相手側の逆行列を使うことで，左右の行列の正の固有値は，勾配の特異値の二乗 σ_i^2 から特異値 σ_i へ変わる．

この極限の行列で勾配を前処理すると，

$$\boldsymbol{A}_\infty^{-p}\boldsymbol{g}\boldsymbol{B}_\infty^{-p} = \boldsymbol{U}\boldsymbol{\Sigma}^{1-2p}\boldsymbol{Q}^\top, \qquad \boldsymbol{A}_\infty^{-1/2}\boldsymbol{g}\boldsymbol{B}_\infty^{-1/2} = \boldsymbol{U}\boldsymbol{Q}^\top \tag{3.29}$$

を得る．極限でゼロとなる固有値については，擬似逆行列の意味で負のべき乗を取っている．これが Proposition 4.8 の結論である．通常の Shampoo では σ_i^2 を持つ行列に $-1/4$ 乗を掛け，この結合した反復の極限では σ_i を持つ行列に $-1/2$ 乗を掛ける．どちらも，左右から $\sigma_i^{-1/2}$ ずつ掛けるため，更新方向の特異値が 1 にそろう．Shampoo の指数の意味は，前処理に使う行列がどのような統計を表すかと合わせて理解できる．この見方から著者らは，$p = 1/2$ の Shampoo が $p = 1/4$ の場合より KL-Shampoo をよく近似する，という仮説を挙げている．

3.3 フィッシャー情報行列とバッチ勾配の二次統計

AdaGrad とフィッシャー情報行列の違いは，勾配の外積を何について平均するかにある．さらに，1 サンプルごとの勾配の外積を平均するのか，バッチで平均した勾配の外積を取るのかによっても，得られる行列は変わる．この違いを，Grosse の講義ノートの式 (2), (4) に沿って調べる [18].

ここではパラメータを再びベクトル $\boldsymbol{\theta} \in \mathbb{R}^d$ として扱い，一つの点に固定する．入力とラベルの組を $z = (\boldsymbol{x}, y)$，訓練データの分布を q とする．前章と同じ分類モデルを用い，1 サンプルの損失を負の対数尤度 $\mathcal{L}_z(\boldsymbol{\theta}) = -\log p_{\boldsymbol{\theta}}(y \mid \boldsymbol{x})$ とし，その勾配を $\boldsymbol{g}(z) := \nabla\mathcal{L}_z(\boldsymbol{\theta})$ と書く．平均損失は $\mathcal{L}(\boldsymbol{\theta}) = \mathbb{E}_{z\sim q}[\mathcal{L}_z(\boldsymbol{\theta})]$ である．勾配の平均を $\bar{\boldsymbol{g}} := \mathbb{E}_{z\sim q}[\boldsymbol{g}(z)] = \nabla\mathcal{L}(\boldsymbol{\theta})$，勾配の共分散を $\boldsymbol{C} := \mathbb{E}_{z\sim q}[(\boldsymbol{g}(z) - \bar{\boldsymbol{g}})(\boldsymbol{g}(z) - \bar{\boldsymbol{g}})^\top]$ とおく[4)].

訓練データのラベルを使った勾配外積の平均を，経験フィッシャー行列（empirical Fisher）と呼ぶ．共分散の定義を展開すれば，

$$\boldsymbol{F}_{\mathrm{emp}} := \mathbb{E}_{z\sim q}[\boldsymbol{g}(z)\boldsymbol{g}(z)^\top] = \boldsymbol{C} + \bar{\boldsymbol{g}}\bar{\boldsymbol{g}}^\top \tag{3.30}$$

となる．これが講義ノートの式 (2) である．

これに対し，前章で導いたフィッシャー情報行列は，入力を同じ分布で平均するとしても，ラベルをモデル自身の予測分布から取る．すなわち，$q_{\boldsymbol{x}}$ を q の入力の周辺分布として，

$$\boldsymbol{F} = \mathbb{E}_{\boldsymbol{x}\sim q_{\boldsymbol{x}}}\mathbb{E}_{y\sim p_{\boldsymbol{\theta}}(\cdot\mid\boldsymbol{x})}[\boldsymbol{g}(\boldsymbol{x}, y)\boldsymbol{g}(\boldsymbol{x}, y)^\top] \tag{3.31}$$

である．モデルの分布で平均すると，スコアの平均はゼロになる．実際，$\sum_y p_{\boldsymbol{\theta}}(y \mid \boldsymbol{x})\nabla \log p_{\boldsymbol{\theta}}(y \mid \boldsymbol{x}) = \nabla \sum_y p_{\boldsymbol{\theta}}(y \mid \boldsymbol{x}) = \boldsymbol{0}$ である．訓練ラベルの条件付き分布がモデルと一致し，$q(y \mid \boldsymbol{x}) = p_{\boldsymbol{\theta}}(y \mid \boldsymbol{x})$ なら，$\boldsymbol{F}_{\mathrm{emp}} = \boldsymbol{F}$ となる．

4) 期待値と微分を交換でき，勾配の二次モーメントが有限であると仮定する．

次に，バッチサイズを B とし，$z_1, \dots, z_B$ を q から独立に取る．バッチ損失をサンプルごとの損失の平均で定義すると，その勾配も

$$\boldsymbol{g}_B := \frac{1}{B} \sum_{i=1}^{B} \boldsymbol{g}(z_i) \tag{3.32}$$

という平均になる．$\mathbb{E}[\boldsymbol{g}_B] = \bar{\boldsymbol{g}}$ である一方，独立性から共分散は $\boldsymbol{C}/B$ になる．したがって，バッチ勾配を使った二次統計は

$$\begin{aligned} \boldsymbol{F}_{\mathrm{emp}}^{(B)} &:= \mathbb{E}[\boldsymbol{g}_B \boldsymbol{g}_B^{\top}] \\ &= \frac{1}{B^2} \left\{ B \boldsymbol{F}_{\mathrm{emp}} + B(B-1) \bar{\boldsymbol{g}} \bar{\boldsymbol{g}}^{\top} \right\} \\ &= \frac{1}{B} \boldsymbol{C} + \bar{\boldsymbol{g}} \bar{\boldsymbol{g}}^{\top} \end{aligned} \tag{3.33}$$

となる．第 2 行では，同じサンプルの積が B 個，異なるサンプル同士の積が $B(B-1)$ 個あることを使った．後者の期待値は独立性によって $\bar{\boldsymbol{g}} \bar{\boldsymbol{g}}^{\top}$ に分かれる．これが講義ノートの式 (4) である．共分散の寄与は $1/B$ に減り，勾配の平均の外積はそのまま残る．

式 (3.30) と式 (3.33) の差は

$$\boldsymbol{F}_{\mathrm{emp}} - \boldsymbol{F}_{\mathrm{emp}}^{(B)} = \left(1 - \frac{1}{B} \right) \boldsymbol{C} \tag{3.34}$$

である．$\boldsymbol{C} \neq \boldsymbol{0}$ なら，$B = 1$ で一致していた二つの行列の差は，B とともに大きくなる．大きなバッチでは共分散の寄与が弱まり，$B \to \infty$ で $\boldsymbol{F}_{\mathrm{emp}}^{(B)} \to \bar{\boldsymbol{g}} \bar{\boldsymbol{g}}^{\top}$ となる．勾配の平均がゼロでなければ，極限で残るのはその方向だけを表す階数 1 の行列である．

ミニバッチで AdaGrad を使うとき，蓄積するのは通常 $\boldsymbol{g}_{B,t} \boldsymbol{g}_{B,t}^{\top}$ である．各時刻のパラメータを固定した条件付き期待値は，式 (3.33) の行列になる．1 サンプルごとの外積を平均した行列とは，平均と外積を取る順序が違う．前者はバッチサイズに依存し，後者の期待値は B によらず $\boldsymbol{F}_{\mathrm{emp}}$ である．したがって，AdaGrad やその構造化近似が整える二次統計は，バッチサイズによっても変わる．さらに，二次統計が $\boldsymbol{F}$ に一致する場合であっても，AdaGrad が掛けるのは累積行列の逆平方根であり，自然勾配法の $\boldsymbol{F}^{-1}$ とは異なる．

第 4 章　ミニバッチ学習

複数の GPU を使うデータ並列学習では，異なるサンプルの勾配を同時に計算できる．各 GPU が処理するサンプル数を保って GPU 台数を増やすと，1 回の更新で使う全体のバッチサイズも大きくなる．ミニバッチを大きくすると，勾配をより小さい分散で推定できる．バッチサイズが大きくなると，更新回数を減らす効果は次第に小さくなる．本章では，バッチサイズを増やす効果が小さくなり始める領域を説明し，二次関数に勾配ノイズを加えたモデルでその理由を調べる．さらに，前処理によって収束とノイズの両方が変わることから，この領域が大きいバッチサイズの側へ移る仕組みを考える．

4.1　クリティカルバッチサイズ

4.1.1　分散学習でバッチサイズを増やす理由

学習時間を短くするために，複数の GPU で勾配計算を分担する場合を考える．同期型のデータ並列学習では，各 GPU が同じパラメータを保持し，異なるサンプルに対して勾配を計算する．その勾配を通信によって集約し，全 GPU で同じ勾配の平均を使ってパラメータを更新する．GPU 台数を m，各 GPU が 1 回に処理するローカルバッチサイズを b とすれば，全体のバッチサイズは $B = mb$ である．以下で単にバッチサイズという場合は，この全体の B を指す．

全体の B を固定したまま GPU を増やすと，各 GPU の担当量 $b = B/m$ は小さくなる．計算量は減るが，更新ごとの勾配の集約は必要である．担当量が小さくなるにつれて通信の占める割合が増え，GPU も十分な効率で計算できなくなることがある．そこで，各 GPU にある程度まとまった計算を割り当てたまま，台数に応じて全体の B を増やすことを考える．これなら，通信時間の増加が小さい範囲では，1 回の更新時間をあまり変えずに，より多くのサンプルを処理できる．

この並列化によって学習時間を短くするには，バッチサイズの増加に伴って必要な更新回数も減ることが必要である．1 回の更新時間を $\tau(m, b)$，目標までの更新回数を $T(B)$ とすれば，学習時間はおおむね $\tau(m, b)T(mb)$ である．ローカルバッチサイズ b を保って GPU 台数を 2 倍にし，τ がほぼ変わらず T が半分になれば，学習時間もほぼ半分になる．逆に，T が減らなくなれば，GPU を増やしても学習時間はほとんど短くならない．クリティカルバッチサイズを調べるのは，計算機を増やす効果を得るために，バッチサイズをどこまで大きくできるかを知りたいからである．

4.1.2　バッチサイズと更新回数

バッチサイズを B とし，同じ初期条件から目標損失 ε に達するまでの更新回数を $T(B)$ と書く．手法を比較する際には，目標損失と学習率の調整方法をそろえておく必要がある．以下では，それ

ぞれの B に応じて学習率を調整した場合を考える．後で導入する確率的なモデルでは，期待損失が ε 以下になるまでの回数を用いる．

勾配ノイズの影響が大きい領域では，バッチサイズを増やすことで大きな学習率を使えるようになり，更新回数が減る場合がある．とくに，B を 2 倍にすると $T(B)$ がほぼ半分になる関係を完全なスケーリング（perfect scaling）と呼ぶ．この領域では，ある係数 K を用いて $T(B) \approx K/B$ と書ける．1 回の更新で B 個のサンプルを使うので，処理する総サンプル数 $BT(B)$ はほぼ一定である．十分に並列計算できれば，総サンプル数をあまり増やさずに更新回数を減らせる．

一方，ノイズを十分小さくすると，更新の進み方はノイズのない最適化に近づく．その場合にも，損失の曲率や最適化手法によって必要な反復回数が決まる．ノイズがない場合の更新回数を T_{det} と書くと，二つの領域の関係は概略

$$T(B) \approx \begin{cases} K/B, & \text{ノイズの影響が大きい領域,} \\ T_{\mathrm{det}}, & \text{ノイズの影響が小さい領域} \end{cases} \tag{4.1}$$

と表せる．実際には，この間にバッチサイズを増やす効果が徐々に小さくなる領域がある．

4.1.3 クリティカルバッチサイズの意味

完全なスケーリングが続く領域から，改善が鈍る領域へ移る目安をクリティカルバッチサイズ（critical batch size），B_{crit} と呼ぶ．その値は，どの程度の改善を境界とするかによって変わる．式 (4.1) の二つの漸近的な関係をつなぐなら，$B_{\mathrm{crit}} \approx K/T_{\mathrm{det}}$ が一つの目安になる．

B_{crit} が大きいとは，バッチサイズの増加によって更新回数を減らせる範囲が広いということである．

この目安は最適化手法によっても変わる．以下では，Zhang らの noisy quadratic model の解析をもとに，前処理による変化を調べる [19]．比較では，目標損失，初期値，学習率の選び方をそろえる．

4.2 Noisy quadratic model

4.2.1 二次損失と勾配ノイズ

損失の曲率と勾配ノイズの役割を分けて調べるために，最小点を原点とする二次関数

$$\mathcal{L}(\boldsymbol{\theta}) = \frac{1}{2}\boldsymbol{\theta}^{\top}\boldsymbol{H}\boldsymbol{\theta} = \frac{1}{2}\sum_{i=1}^{d} h_i \theta_i^2 \tag{4.2}$$

を考える．ここで $\boldsymbol{H} = \mathrm{diag}(h_1, \ldots, h_d)$，$h_1 \geq \cdots \geq h_d > 0$ とする．正定値の二次関数は，固有ベクトルを座標軸に選べばこの形になる．真の勾配は $\nabla\mathcal{L}(\boldsymbol{\theta}) = \boldsymbol{H}\boldsymbol{\theta}$ だが，各反復ではノイズを含む勾配

$$\boldsymbol{g}_B^{(k)} = \boldsymbol{H}\boldsymbol{\theta}^{(k)} + \boldsymbol{\xi}^{(k)}, \qquad \mathbb{E}[\boldsymbol{\xi}^{(k)} \mid \boldsymbol{\theta}^{(k)}] = \mathbf{0}, \qquad \mathrm{Cov}(\boldsymbol{\xi}^{(k)} \mid \boldsymbol{\theta}^{(k)}) = \frac{\boldsymbol{C}}{B} \tag{4.3}$$

を使うと仮定する．毎回新しいサンプルから独立にノイズが生じ，その共分散 $\boldsymbol{C}$ はパラメータによらないものとする．独立な B 個の勾配の平均を使うため，ノイズの共分散は 1 サンプルの場合の $1/B$ になる．

さらに，$\boldsymbol{C} = \mathrm{diag}(c_1, \ldots, c_d)$，$c_i \geq 0$ とする．$\boldsymbol{H}$ と $\boldsymbol{C}$ を同じ座標で対角行列にできることは，解析のための追加の仮定である．このように，二次損失に対してノイズを含む勾配を観測する設定を noisy quadratic model（NQM）と呼ぶ．実際のニューラルネットワークでは，曲率もノイズ共分散も学習中に変わる．ここではそれらを固定して，バッチサイズが更新回数を変える仕組みを調べる．

4.2.2 期待損失の時間変化

一定の学習率 $\eta > 0$ を用いた確率的勾配降下法は，各成分について

$$\theta_i^{(k+1)} = (1 - \eta h_i)\theta_i^{(k)} - \eta \xi_i^{(k)} \tag{4.4}$$

となる．右辺を二乗して期待値をとると，現在のパラメータとノイズとの交差項はゼロになる．したがって，

$$\mathbb{E}[(\theta_i^{(k+1)})^2] = (1 - \eta h_i)^2 \mathbb{E}[(\theta_i^{(k)})^2] + \frac{\eta^2 c_i}{B} \tag{4.5}$$

を得る．第 1 項は前の反復から残る誤差，第 2 項はその回の勾配ノイズによって加わる分である．

各方向の損失を $\ell_i(\theta_i) = h_i \theta_i^2/2$ とし，$q_i = 1 - \eta h_i$ とおく．すべての方向で $|q_i| < 1$，すなわち $0 < \eta < 2/h_1$ を仮定する．式 (4.5) を繰り返し使うと，ノイズの寄与には $\sum_{j=0}^{k-1} q_i^{2j} = (1 - q_i^{2k})/(1 - q_i^2)$ が現れる．これを用いて，期待損失は

$$\mathbb{E}[\ell_i(\theta_i^{(k)})] = q_i^{2k} \mathbb{E}[\ell_i(\theta_i^{(0)})] + (1 - q_i^{2k}) \frac{\eta c_i}{2B(2 - \eta h_i)} \tag{4.6}$$

と求まる．全体の期待損失は，この式を i について足し合わせればよい．

第 1 項は初期値の影響を表し，反復とともにゼロに近づく．第 2 項は，一定の学習率のもとでノイズによって生じる損失である．極限 $k \to \infty$ で残る損失を定常損失と呼ぶと，その値は

$$R_{\mathrm{ss}} := \lim_{k \to \infty} \mathbb{E}[\mathcal{L}(\boldsymbol{\theta}^{(k)})] = \frac{1}{2B} \sum_{i=1}^{d} \frac{\eta c_i}{2 - \eta h_i} \tag{4.7}$$

である．B を増やすと定常損失は小さくなるが，初期値の影響の減衰率 q_i^{2k} は，同じ学習率なら変わらない．バッチサイズを増やすことと学習率を変えることは，このように別の操作である．

4.3 前処理によるクリティカルバッチサイズの増大

4.3.1 収束速度と更新ノイズ

前処理行列を $\boldsymbol{H}^{-p}$（$0 \leq p \leq 1$）と選び，確率的勾配に掛ける．$p = 0$ は通常の SGD，$p = 1$ はヘッセ行列の逆行列による前処理である．このモデルでは $\boldsymbol{H}$ が固定されているので，前処理行列

も反復中に変化しない．更新式を成分ごとに書くと，

$$\theta_i^{(k+1)} = (1 - \eta h_i^{1-p})\theta_i^{(k)} - \eta h_i^{-p}\xi_i^{(k)} \tag{4.8}$$

となる．前処理は真の勾配とノイズの両方に掛かる．第 1 項では有効な曲率が h_i から h_i^{1-p} に変わり，第 2 項ではノイズに h_i^{-p} が掛かっている．

元の条件数を $\kappa = h_1/h_d$ とすると，前処理後の条件数は

$$\widetilde{\kappa} = \frac{h_1^{1-p}}{h_d^{1-p}} = \kappa^{1-p} \tag{4.9}$$

である．p を大きくするとこの比が小さくなり，$p = 1$ では 1 になる．実際に，ノイズがない場合に学習率を $\eta_{\mathrm{fast}} = h_1^{-(1-p)}$ と選べば，各方向の反復の倍率は $1-(h_i/h_1)^{1-p}$ となる．これらは 0 以上 1 未満であり，p を大きくするほど小さくなる．したがって，同じ初期値からの損失は速く減少する．$p = 1$ なら，全成分が 1 回の更新でゼロになる．これは正確な二次損失と正確な前処理についての結果である．

一方，式 (4.8) で加わる更新ノイズの分散は

$$\mathrm{Var}(\eta h_i^{-p}\xi_i^{(k)}) = \frac{\eta^2 c_i h_i^{-2p}}{B} \tag{4.10}$$

となる．先ほどの η_{fast} を使うと，ノイズに掛かる係数は $\eta_{\mathrm{fast}} h_i^{-p} = h_1^{-1}(h_1/h_i)^p$ である．最大曲率に比べて曲率の小さい方向ほど，p を増やしたときのノイズの増幅が大きい．学習率をこのようにそろえて比較すれば，固有値の絶対的な大きさに依存せずに増幅を説明できる．

4.3.2 ノイズによる学習率の制限

前処理を入れた場合も，二乗の期待値について同じ計算ができる．$q_{i,p} = 1 - \eta h_i^{1-p}$ とおき，安定性条件 $0 < \eta < 2/h_1^{1-p}$ を仮定すると，

$$\mathbb{E}[\ell_i(\theta_i^{(k)})] = q_{i,p}^{2k}\mathbb{E}[\ell_i(\theta_i^{(0)})] + (1 - q_{i,p}^{2k})\frac{\eta c_i h_i^{-p}}{2B(2 - \eta h_i^{1-p})} \tag{4.11}$$

を得る．したがって，定常損失は

$$R_{\mathrm{ss}}(\eta, p, B) = \frac{\eta}{2B}\sum_{i=1}^{d}\frac{c_i h_i^{-p}}{2 - \eta h_i^{1-p}} \tag{4.12}$$

となる．

目標損失 ε に余裕をもって到達するため，定常損失をその一定割合以下，$R_{\mathrm{ss}} \le r\varepsilon$（$0 < r < 1$）に抑えるものとする．実際，式 (4.11) の初期値の項の和を $(1-r)\varepsilon$ 以下にすれば，全体の期待損失も ε 以下になる．

$\eta h_1^{1-p} \ll 1$ の範囲では，$S_p := \sum_i c_i h_i^{-p}$ とおくと，

$$R_{\mathrm{ss}} \approx \frac{\eta S_p}{4B}, \qquad \eta \lesssim \frac{4r\varepsilon B}{S_p} \tag{4.13}$$

となる．バッチサイズが小さく，この条件によって学習率が制限される間は，B にほぼ比例して学習率を増やせる．また，小さい学習率では $q_{i,p}^{2k} \approx \exp(-2\eta h_i^{1-p} k)$ だから，初期値の項を一定の割合まで減らす回数はおおむね $1/\eta$ に比例する．この二つの関係を合わせると，$T(B) \propto 1/B$ という小バッチ領域の挙動を説明できる．

ノイズが十分小さくなれば，学習率は曲率による安定性条件のもとで，決定論的な収束に適した値で決まる．この段階では，さらに B を増やすことで得られる更新回数の減少は小さくなる．次に，近似前の定常損失を使って，大きな学習率を使えるバッチサイズを調べる．

4.3.3 速い更新に必要なバッチサイズ

比較する学習率を再び $\eta_{\mathrm{fast}} = h_1^{-(1-p)}$ とする．これは全方向で安定であり，ノイズのない場合には最大曲率方向の誤差を 1 回でゼロにする．さらに，ここではノイズ共分散と曲率の関係を $\boldsymbol{C} = \boldsymbol{H}$ と仮定する．これは Zhang らの論文でも用いられた設定である．

$x_i(p) := (h_i/h_1)^{1-p}$ とおき，式 (4.12) に代入すると，

$$R_{\mathrm{ss}}(\eta_{\mathrm{fast}}, p, B) = \frac{1}{2B} \sum_{i=1}^{d} \frac{x_i(p)}{2 - x_i(p)} \tag{4.14}$$

となる．$0 < h_i/h_1 \leq 1$ なので，p を大きくすると $x_i(p)$ は減少しない．さらに，$x/(2-x)$ は $0 < x \leq 1$ で単調増加する．したがって，この学習率を使った定常損失は，前処理を強くするほど大きくなるか，同じ値にとどまる．

$R_{\mathrm{ss}} \leq r\varepsilon$ を満たす条件をバッチサイズについて解くと，

$$B \geq B_{\mathrm{fast}}(p) := \frac{1}{2r\varepsilon} \sum_{i=1}^{d} \frac{x_i(p)}{2 - x_i(p)} \tag{4.15}$$

を得る．右辺は p に対して単調非減少であり，最大固有値より小さい固有値があれば，p とともに厳密に増える．とくに $p = 1$ ではすべての x_i が 1 になり，$B_{\mathrm{fast}}(1) = d/(2r\varepsilon)$ である．前処理によって決定論的な収束が速くなる一方で，その学習率を使ったままノイズを抑えるには，より大きなバッチが必要になることが分かる．

B_{fast} は指定した学習率で定常損失を抑えるための目安である．B_{crit} を具体的に求めるには，初期値と目標損失を決め，学習率を調整しながら式 (4.11) から到達回数を比較する必要がある．式 (4.15) は，前処理を強くするほど大きなバッチサイズまでノイズが学習率を制限しうることを示している．同時に，ノイズが小さい領域では決定論的な更新回数も減る．この二つの変化が，前処理によってクリティカルバッチサイズが大きくなる理由である．

実際の学習では，前処理がどの方向の収束を速め，その方向のノイズをどの程度変えるかを併せて調べる必要がある．

4.4 確率的分散縮小アルゴリズム

第 5 章　線形ネットワーク

5.1　自然勾配法の学習ダイナミクス

第 4 章では，二次損失の曲率を前処理でそろえると，方向による収束の速さの違いを取り除けることを見た．では，複数の層を持つネットワークでは，自然勾配法によって学習はどのように進むのだろうか．ここでは，活性化関数を恒等写像にした線形ネットワークを使って，この問いを調べる．線形層を重ねたモデルの出力は，重み行列の積で決まる．自然勾配法による学習をこの積と関数出力の時間変化として見ると，最適な線形写像への指数収束を具体的に計算できる [20].

5.1.1　線形ネットワークと回帰問題

入力と出力をともに n 次元とし，L 層の線形ネットワークを考える．第 ℓ 層の重み行列を $\boldsymbol{W}_\ell \in \mathbb{R}^{n\times n}$ とし，バイアスはゼロとする．入力 $\boldsymbol{x}$ から各層の出力を順に計算すると，

$$\boldsymbol{x}_0 = \boldsymbol{x}, \qquad \boldsymbol{x}_\ell = \boldsymbol{W}_\ell \boldsymbol{x}_{\ell-1} \quad (\ell = 1, \dots, L) \tag{5.1}$$

となる．重み行列の積は，層番号の大きい方から順に掛ける約束で

$$\boldsymbol{W}_{s:t} := \boldsymbol{W}_s \boldsymbol{W}_{s-1} \cdots \boldsymbol{W}_t \quad (s \geq t), \qquad \boldsymbol{W}_{t-1:t} := \boldsymbol{I} \tag{5.2}$$

と書く．たとえば $\boldsymbol{W}_{3:1} = \boldsymbol{W}_3 \boldsymbol{W}_2 \boldsymbol{W}_1$ であり，ネットワーク全体の出力は $\boldsymbol{x}_L = \boldsymbol{W}_{L:1}\boldsymbol{x}$ となる．層を重ねても，入力から出力への写像は一つの行列 $\boldsymbol{W}_{L:1}$ で表せる．すべての層の成分を列ごとに並べ，さらに層の順に連結したパラメータベクトルを $\boldsymbol{\theta} \in \mathbb{R}^{Ln^2}$ と書く．この写像を関数として書けば，$\boldsymbol{f}_{\boldsymbol{\theta}}(\boldsymbol{x}) = \boldsymbol{W}_{L:1}\boldsymbol{x}$ である．各層の重みの値が異なっていても，積 $\boldsymbol{W}_{L:1}$ が同じなら，すべての入力に対して同じ出力を返す．学習で動かすのは各層の $\boldsymbol{W}_\ell$ だが，予測を決めるのはそれらの積である．そこで本節では，積 $\boldsymbol{W}_{L:1}$ と，それが表す関数の出力が最適解へ近づく様子を追う．

第 2 章の自然勾配法をこの回帰モデルに適用するため，出力の予測分布を

$$p_{\boldsymbol{\theta}}(\boldsymbol{y} \mid \boldsymbol{x}) = \mathcal{N}(\boldsymbol{y}; \boldsymbol{W}_{L:1}\boldsymbol{x}, \boldsymbol{\Sigma}_y), \qquad \boldsymbol{\Sigma}_y \succ \boldsymbol{0} \tag{5.3}$$

と定める．$\boldsymbol{\Sigma}_y$ は固定した共分散行列であり，モデルの平均だけを学習する．訓練データの分布を第 3 章と同じく q と書き，負の対数尤度のうちパラメータに依存する部分を損失とする．ガウス密度の対数を取ると，

$$\mathcal{L}(\boldsymbol{\theta}) = \frac{1}{2}\mathbb{E}_{(\boldsymbol{x},\boldsymbol{y})\sim q}\left[(\boldsymbol{y} - \boldsymbol{W}_{L:1}\boldsymbol{x})^\top \boldsymbol{\Sigma}_y^{-1} (\boldsymbol{y} - \boldsymbol{W}_{L:1}\boldsymbol{x})\right] \tag{5.4}$$

となる．$\boldsymbol{\Sigma}_y = \boldsymbol{I}$ なら，通常の二乗誤差である．

入力の二次モーメントを $\boldsymbol{\Sigma}_x := \mathbb{E}_q[\boldsymbol{x}\boldsymbol{x}^\top]$ とおき，正定値であるとする[1)]．まず，各層への分解を考える前に，一つの行列として最適な線形写像を求める．$\boldsymbol{\Sigma}_{yx} := \mathbb{E}_q[\boldsymbol{y}\boldsymbol{x}^\top]$ とおくと，積行列に関する勾配は

$$\boldsymbol{g}_{\mathrm{tot}} := \nabla_{\boldsymbol{W}_{L:1}} \mathcal{L} = \boldsymbol{\Sigma}_y^{-1}(\boldsymbol{W}_{L:1}\boldsymbol{\Sigma}_x - \boldsymbol{\Sigma}_{yx}) \tag{5.5}$$

である．これをゼロとおけば，最適な積行列は

$$\boldsymbol{W}_{L:1}^{*} = \boldsymbol{\Sigma}_{yx}\boldsymbol{\Sigma}_x^{-1} \tag{5.6}$$

と求まる．以下では，各層の学習によって，この行列へどのように近づくかを見る．

5.1.2 通常の勾配とフィッシャー情報行列

一つの層を変えたとき，出力がどう変わるかを計算する．第 ℓ 層より後と前の重みの積は，それぞれ $\boldsymbol{W}_{L:\ell+1}$，$\boldsymbol{W}_{\ell-1:1}$ である．端の層では，空の積の約束により $\boldsymbol{W}_{L:L+1} = \boldsymbol{W}_{0:1} = \boldsymbol{I}$ となる．この記号を使うと $\boldsymbol{W}_{L:1} = \boldsymbol{W}_{L:\ell+1}\boldsymbol{W}_\ell\boldsymbol{W}_{\ell-1:1}$ であり，第 ℓ 層だけに変化 $d\boldsymbol{W}_\ell$ を加えたときの積行列の変化は $d\boldsymbol{W}_{L:1} = \boldsymbol{W}_{L:\ell+1}\, d\boldsymbol{W}_\ell\, \boldsymbol{W}_{\ell-1:1}$ となる．したがって，連鎖律から，各層の勾配は

$$\boldsymbol{g}_\ell := \nabla_{\boldsymbol{W}_\ell}\mathcal{L} = \boldsymbol{W}_{L:\ell+1}^\top \boldsymbol{g}_{\mathrm{tot}} \boldsymbol{W}_{\ell-1:1}^\top \tag{5.7}$$

である．

時間変化を調べるため，ここからは連続時間 t を使う．通常の勾配降下法の連続時間での式を $d\boldsymbol{W}_\ell/dt = -\eta \boldsymbol{g}_\ell$（$\eta > 0$）とすると，積の微分により

$$\frac{d\boldsymbol{W}_{L:1}}{dt} = \sum_{\ell=1}^{L} \boldsymbol{W}_{L:\ell+1}\frac{d\boldsymbol{W}_\ell}{dt}\boldsymbol{W}_{\ell-1:1} = -\eta \sum_{\ell=1}^{L} \boldsymbol{W}_{L:\ell+1}\boldsymbol{W}_{L:\ell+1}^\top \boldsymbol{g}_{\mathrm{tot}} \boldsymbol{W}_{\ell-1:1}^\top \boldsymbol{W}_{\ell-1:1} \tag{5.8}$$

を得る．同じ積行列を表す重みでも，各層への分解の仕方によって進み方が変わる．たとえば，$n = 1$，$L = 2$，$\boldsymbol{\Sigma}_x = \boldsymbol{\Sigma}_y = 1$ として，二つの重みを a, b，最適な積を s と書けば，$d(ab)/dt = -\eta(a^2 + b^2)(ab - s)$ となる．目標までの差が同じでも，a, b がともに小さいと積の変化は遅くなる．

自然勾配法では，予測分布の変化を表すフィッシャー情報行列 $\boldsymbol{F}$ を使って，この更新を調整する．その構造を見るため，出力の残差を各層へ戻したベクトルを $\boldsymbol{e}_\ell := \boldsymbol{W}_{L:\ell+1}^\top \boldsymbol{\Sigma}_y^{-1}(\boldsymbol{y} - \boldsymbol{W}_{L:1}\boldsymbol{x})$ とおく．1 サンプルの負の対数尤度の勾配は $-\boldsymbol{e}_\ell \boldsymbol{x}_{\ell-1}^\top$ である．フィッシャー情報行列を計算するときは，入力を q の周辺分布 $q_{\boldsymbol{x}}$ から取り，出力をモデルの予測分布 $p_{\boldsymbol{\theta}}(\cdot \mid \boldsymbol{x})$ から取る．この平均を $\mathbb{E}_{p_{\boldsymbol{\theta}}}$ と書くと，モデルの残差の条件付き平均はゼロ，共分散は $\boldsymbol{\Sigma}_y$ なので，

$$\mathbb{E}_{p_{\boldsymbol{\theta}}}[\boldsymbol{e}_\ell \boldsymbol{e}_j^\top \mid \boldsymbol{x}] = \boldsymbol{W}_{L:\ell+1}^\top \boldsymbol{\Sigma}_y^{-1} \boldsymbol{W}_{L:j+1} \tag{5.9}$$

となる．右辺は入力によらない．また，$\boldsymbol{x}_{\ell-1} = \boldsymbol{W}_{\ell-1:1}\boldsymbol{x}$ だから，$\mathbb{E}_{q_{\boldsymbol{x}}}[\boldsymbol{x}_{\ell-1}\boldsymbol{x}_{j-1}^\top] = \boldsymbol{W}_{\ell-1:1}\boldsymbol{\Sigma}_x\boldsymbol{W}_{j-1:1}^\top$ である．両者を使うと，層 ℓ, j に対応するフィッシャー情報行列のブロックは

$$\boldsymbol{F}_{\ell j} = (\boldsymbol{W}_{\ell-1:1}\boldsymbol{\Sigma}_x\boldsymbol{W}_{j-1:1}^\top) \otimes (\boldsymbol{W}_{L:\ell+1}^\top \boldsymbol{\Sigma}_y^{-1}\boldsymbol{W}_{L:j+1}) \tag{5.10}$$

1) 入力と出力の二次モーメントは有限とする．

と求まる．ここで $\otimes$ は第 3 章で使ったクロネッカー積であり，行列の成分は列ごとに並べている．

$L \geq 2$ では，予測分布を定める $\boldsymbol{W}_{L:1}$ の成分数 n^2 に対し，全層のパラメータ数は Ln^2 ある．たとえば，可逆行列 $\boldsymbol{R}$ を使って隣り合う二層を $\boldsymbol{R}\boldsymbol{W}_\ell$，$\boldsymbol{W}_{\ell+1}\boldsymbol{R}^{-1}$ に変えても，積は同じである．このように予測分布を変えないパラメータの変化があるため，$\boldsymbol{F}$ は特異になる．そこで，自然勾配の方向 $\boldsymbol{v}$ を $\boldsymbol{F}\boldsymbol{v} = \nabla_{\boldsymbol{\theta}}\mathcal{L}$ の解として求め，$d\boldsymbol{\theta}/dt = -\eta\boldsymbol{v}$ とする．この方程式の解の一つを，層ごとの行列で構成する．

5.1.3 各層の自然勾配を求める

以下では，各層の重み行列が可逆である区間を考える．第 ℓ 層の入力と，モデルの分布で平均した逆伝播誤差の二次統計を，それぞれ

$$\begin{aligned}\boldsymbol{\Lambda}_\ell &:= \mathbb{E}_{q_{\boldsymbol{x}}}[\boldsymbol{x}_{\ell-1}\boldsymbol{x}_{\ell-1}^\top] = \boldsymbol{W}_{\ell-1:1}\boldsymbol{\Sigma}_x\boldsymbol{W}_{\ell-1:1}^\top, \\ \boldsymbol{\Omega}_\ell &:= \mathbb{E}_{p_{\boldsymbol{\theta}}}[\boldsymbol{e}_\ell\boldsymbol{e}_\ell^\top] = \boldsymbol{W}_{L:\ell+1}^\top\boldsymbol{\Sigma}_y^{-1}\boldsymbol{W}_{L:\ell+1}\end{aligned} \tag{5.11}$$

とおく．これらは $n \times n$ の正定値行列である．式 (5.10) の対角ブロックは $\boldsymbol{F}_{\ell\ell} = \boldsymbol{\Lambda}_\ell \otimes \boldsymbol{\Omega}_\ell$ なので，その逆行列を勾配に作用させる操作は，行列の形では $\boldsymbol{\Omega}_\ell^{-1}\boldsymbol{g}_\ell\boldsymbol{\Lambda}_\ell^{-1}$ となる．この左右からの前処理を使い，各層の方向を

$$\boldsymbol{v}_\ell = \frac{1}{L}\boldsymbol{\Omega}_\ell^{-1}\boldsymbol{g}_\ell\boldsymbol{\Lambda}_\ell^{-1} \tag{5.12}$$

と選ぶ．$\boldsymbol{v}_\ell$ を各層の順にベクトル化して連結したものが $\boldsymbol{v}$ である．係数 $1/L$ は，L 個の層が積行列の変化を分担することに対応する．これが層間のブロックも含めた $\boldsymbol{F}\boldsymbol{v} = \nabla_{\boldsymbol{\theta}}\mathcal{L}$ の解になることを確かめる．

まず，逆行列を展開すると，$\boldsymbol{\Omega}_\ell^{-1} = \boldsymbol{W}_{L:\ell+1}^{-1}\boldsymbol{\Sigma}_y\boldsymbol{W}_{L:\ell+1}^{-\top}$，$\boldsymbol{\Lambda}_\ell^{-1} = \boldsymbol{W}_{\ell-1:1}^{-\top}\boldsymbol{\Sigma}_x^{-1}\boldsymbol{W}_{\ell-1:1}^{-1}$ である．式 (5.7) を代入すれば，

$$\begin{aligned}\boldsymbol{v}_\ell &= \frac{1}{L}\boldsymbol{W}_{L:\ell+1}^{-1}\boldsymbol{\Sigma}_y\boldsymbol{g}_{\mathrm{tot}}\boldsymbol{\Sigma}_x^{-1}\boldsymbol{W}_{\ell-1:1}^{-1} \\ &= \frac{1}{L}\boldsymbol{W}_{L:\ell+1}^{-1}(\boldsymbol{W}_{L:1} - \boldsymbol{W}_{L:1}^*)\boldsymbol{W}_{\ell-1:1}^{-1}\end{aligned} \tag{5.13}$$

となる．第 2 行では式 (5.5) と式 (5.6) を使った．左右の前処理によって，通常の勾配に含まれていた他の層の転置行列が，逆行列へ置き換わった．

次に，$\mathrm{vec}(\boldsymbol{P}\boldsymbol{Q}\boldsymbol{R}) = (\boldsymbol{R}^\top \otimes \boldsymbol{P})\,\mathrm{vec}(\boldsymbol{Q})$ を使い，第 ℓ ブロックにおける $\boldsymbol{F}\boldsymbol{v}$ を計算する．式 (5.10) から，

$$\begin{aligned}\sum_{j=1}^{L}\boldsymbol{F}_{\ell j}\,\mathrm{vec}(\boldsymbol{v}_j) &= \mathrm{vec}\left[\boldsymbol{W}_{L:\ell+1}^\top\boldsymbol{\Sigma}_y^{-1}\left(\sum_{j=1}^{L}\boldsymbol{W}_{L:j+1}\boldsymbol{v}_j\boldsymbol{W}_{j-1:1}\right)\boldsymbol{\Sigma}_x\boldsymbol{W}_{\ell-1:1}^\top\right] \\ &= \mathrm{vec}\big[\boldsymbol{W}_{L:\ell+1}^\top\boldsymbol{\Sigma}_y^{-1}(\boldsymbol{W}_{L:1} - \boldsymbol{W}_{L:1}^*)\boldsymbol{\Sigma}_x\boldsymbol{W}_{\ell-1:1}^\top\big] = \mathrm{vec}(\boldsymbol{g}_\ell)\end{aligned} \tag{5.14}$$

を得る．各 $\boldsymbol{W}_{L:j+1}\boldsymbol{v}_j\boldsymbol{W}_{j-1:1}$ が $(\boldsymbol{W}_{L:1} - \boldsymbol{W}_{L:1}^*)/L$ に等しいため，和を取ると係数 $1/L$ が消える．こうして，式 (5.12) は，全体のフィッシャー情報行列に対する自然勾配の方向を与える．大きさ $Ln^2 \times Ln^2$ の行列全体を構成する代わりに，各層で二つの $n \times n$ の行列を使って計算できた．

5.1.4 積行列と損失の指数収束

求めた自然勾配による各層の時間変化は,

$$\frac{d\boldsymbol{W}_\ell}{dt} = -\frac{\eta}{L}\boldsymbol{\Omega}_\ell^{-1}\boldsymbol{g}_\ell\boldsymbol{\Lambda}_\ell^{-1} = -\frac{\eta}{L}\boldsymbol{W}_{L:\ell+1}^{-1}(\boldsymbol{W}_{L:1} - \boldsymbol{W}_{L:1}^*)\boldsymbol{W}_{\ell-1:1}^{-1} \tag{5.15}$$

である．これを積の微分に代入すると，各層の前後にあった行列が相殺され,

$$\begin{aligned}\frac{d\boldsymbol{W}_{L:1}}{dt} &= \sum_{\ell=1}^{L} \boldsymbol{W}_{L:\ell+1}\frac{d\boldsymbol{W}_\ell}{dt}\boldsymbol{W}_{\ell-1:1} \\ &= -\frac{\eta}{L}\sum_{\ell=1}^{L}(\boldsymbol{W}_{L:1} - \boldsymbol{W}_{L:1}^*) = -\eta(\boldsymbol{W}_{L:1} - \boldsymbol{W}_{L:1}^*)\end{aligned} \tag{5.16}$$

となる．通常の勾配で現れた式 (5.8) の $\boldsymbol{W}_{L:\ell+1}\boldsymbol{W}_{L:\ell+1}^\top$ や $\boldsymbol{W}_{\ell-1:1}^\top\boldsymbol{W}_{\ell-1:1}$ が取り除かれた．積行列の各成分は，目標までの差に比例する速さで動く．この微分方程式を解けば,

$$\boldsymbol{W}_{L:1}(t) - \boldsymbol{W}_{L:1}^* = e^{-\eta t}\big(\boldsymbol{W}_{L:1}(0) - \boldsymbol{W}_{L:1}^*\big) \tag{5.17}$$

を得る．可逆性が保たれる軌道では，積行列は最適な線形写像へ指数的に収束する．係数 $1/L$ で各層の更新をそろえたことで，この収束率は深さ L にも重みの分解の仕方にも依存しない．先ほどの二層のスカラーの例なら，$d(ab)/dt = -\eta(ab - s)$ であり，通常の勾配にあった $a^2 + b^2$ による速度の変化が消える．

関数出力の収束も，この式から直接分かる．時刻 t の出力を $\boldsymbol{f}_t(\boldsymbol{x}) := \boldsymbol{W}_{L:1}(t)\boldsymbol{x}$，最適な線形写像の出力を $\boldsymbol{f}_*(\boldsymbol{x}) := \boldsymbol{W}_{L:1}^*\boldsymbol{x}$ と書く．式 (5.17) の右から入力 $\boldsymbol{x}$ を掛けると,

$$\boldsymbol{f}_t(\boldsymbol{x}) - \boldsymbol{f}_*(\boldsymbol{x}) = e^{-\eta t}\big(\boldsymbol{f}_0(\boldsymbol{x}) - \boldsymbol{f}_*(\boldsymbol{x})\big) \tag{5.18}$$

を得る．どの入力に対しても，出力の誤差が同じ率で指数的に減少する．各層への重みの分解が異なっていても，初期の積行列が同じなら，関数出力は同じ時間変化をたどる．

最後に，この結果から損失の変化を求める．最適な積行列における損失を $\mathcal{L}_*$，積行列の誤差を $\boldsymbol{\Delta}(t) := \boldsymbol{W}_{L:1}(t) - \boldsymbol{W}_{L:1}^*$ と書く．式 (5.4) で残差を $\boldsymbol{y} - \boldsymbol{W}_{L:1}^*\boldsymbol{x} - \boldsymbol{\Delta}\boldsymbol{x}$ と分けると，$\mathbb{E}_q[(\boldsymbol{y} - \boldsymbol{W}_{L:1}^*\boldsymbol{x})\boldsymbol{x}^\top] = \boldsymbol{\Sigma}_{yx} - \boldsymbol{W}_{L:1}^*\boldsymbol{\Sigma}_x = \boldsymbol{0}$ により交差項が消える．したがって，最小損失との差は

$$\mathcal{L}(\boldsymbol{\theta}(t)) - \mathcal{L}_* = \frac{1}{2}\operatorname{Tr}\big[\boldsymbol{\Sigma}_y^{-1}\boldsymbol{\Delta}(t)\boldsymbol{\Sigma}_x\boldsymbol{\Delta}(t)^\top\big] = e^{-2\eta t}\big(\mathcal{L}(\boldsymbol{\theta}(0)) - \mathcal{L}_*\big) \tag{5.19}$$

となる．積行列の誤差が $e^{-\eta t}$ 倍になり，損失差はその二次式なので $e^{-2\eta t}$ 倍になる．線形写像で出力を完全に表せるデータなら $\mathcal{L}_* = 0$ であり，損失そのものがこの速さでゼロへ近づく．

この収束則は，損失の勾配とフィッシャー情報行列を使った連続時間の式から得られたものである．離散時間の学習では，反復 k で各量を評価し，$\boldsymbol{W}_\ell^{(k+1)} = \boldsymbol{W}_\ell^{(k)} - (\eta/L)\boldsymbol{\Omega}_{\ell,k}^{-1}\boldsymbol{g}_{\ell,k}\boldsymbol{\Lambda}_{\ell,k}^{-1}$ と更新する．この式の積行列の変化は，学習率の一次までで式 (5.16) に対応する．

自然勾配法の収束を理解するうえで，ここで直接追えたのは，重みの積と，その積が定める関数出力である．各層の更新には他の層の重みが現れるが，積行列と関数出力の時間変化ではそれらが相殺され，最適な線形写像への誤差だけが残る．その結果，出力の誤差は $e^{-\eta t}$，最小損失との差は $e^{-2\eta t}$ に比例して減少する．

5.2 Saxe Solution と Fukumizu Solution

線形ネットワークの学習では，重みの積の特異値がどう変化するかを調べることが多い．特異値は，対応する入力方向の成分を出力へどの強さで伝えるかを表す．その時間変化が分かれば，どの成分が先に学習され，どの成分が遅れるかを説明できる．ここでは，通常の勾配降下法について，特異値ごとに独立な方程式を得る Saxe 解と，行列のまま解く Fukumizu 解を順に説明する．

5.2.1 特異値ごとの力学系

前節の設定で $\boldsymbol{\Sigma}_x = \boldsymbol{\Sigma}_y = \boldsymbol{I}$ とする．このとき最適な積行列は $\boldsymbol{W}^*_{L:1} = \boldsymbol{\Sigma}_{yx}$ であり，損失差は

$$\mathcal{L} - \mathcal{L}_* = \frac{1}{2}\|\boldsymbol{W}_{L:1} - \boldsymbol{\Sigma}_{yx}\|_{\mathrm{F}}^2 \tag{5.20}$$

である．目標の写像を特異値分解して $\boldsymbol{\Sigma}_{yx} = \boldsymbol{U}\boldsymbol{\Sigma}_*\boldsymbol{V}^\top$，$\boldsymbol{\Sigma}_* = \mathrm{diag}(s_1^*, \dots, s_n^*)$ と書く．以下では $s_i^* > 0$ のモードを考える．第 i モードとは，入力の右特異ベクトル $\boldsymbol{v}_i$ に沿った成分を，左特異ベクトル $\boldsymbol{u}_i$ の方向へ写す成分のことである．目標の写像では，この成分を s_i^* 倍して出力する．

まず，重みの特異ベクトルが初めからこの目標にそろっている場合を考える．各層の重みを

$$\boldsymbol{W}_\ell = \boldsymbol{R}_\ell \,\mathrm{diag}(\sigma_{\ell,1}, \dots, \sigma_{\ell,n})\boldsymbol{R}_{\ell-1}^\top, \qquad \boldsymbol{R}_0 = \boldsymbol{V}, \quad \boldsymbol{R}_L = \boldsymbol{U} \tag{5.21}$$

と書く．$\boldsymbol{R}_1, \dots, \boldsymbol{R}_{L-1}$ は固定した直交行列であり，$\sigma_{\ell,i}$ は正とする．隣り合う層の直交行列が相殺されるので，積行列は

$$\boldsymbol{W}_{L:1} = \boldsymbol{U}\,\mathrm{diag}(s_1, \dots, s_n)\boldsymbol{V}^\top, \qquad s_i := \prod_{\ell=1}^{L} \sigma_{\ell,i} \tag{5.22}$$

となる．s_i が学習中の写像の第 i モードの強さであり，目標は $s_i = s_i^*$ である．この形では，損失差は $\frac{1}{2}\sum_i (s_i - s_i^*)^2$ とモードごとに分かれる．

この整列条件は，隠れ層の空間での可換性としても表せる．隣り合う層の二次統計 $\boldsymbol{W}_\ell\boldsymbol{W}_\ell^\top$ と $\boldsymbol{W}_{\ell+1}^\top\boldsymbol{W}_{\ell+1}$ は，ともに $\boldsymbol{R}_\ell$ を基底として対角化される．したがって，交換子を $[\boldsymbol{A}, \boldsymbol{B}] := \boldsymbol{A}\boldsymbol{B} - \boldsymbol{B}\boldsymbol{A}$ と書くと，

$$[\boldsymbol{W}_\ell\boldsymbol{W}_\ell^\top, \boldsymbol{W}_{\ell+1}^\top\boldsymbol{W}_{\ell+1}] = \boldsymbol{0} \quad (\ell = 1, \dots, L-1) \tag{5.23}$$

となる．この意味で，隣り合う層は同じモードを共有する．

各層の勾配にも同じ直交行列が現れるため，勾配降下法は式 (5.21) の形を保つ．その対角成分だけを取り出すと，

$$\frac{d\sigma_{\ell,i}}{dt} = \eta(s_i^* - s_i) \prod_{j \neq \ell} \sigma_{j,i} \tag{5.24}$$

を得る [21]．異なるモード間の結合が消え，各モードについて L 個の重みを追えばよくなった．さらに，層間で初期値の大きさをそろえ，$\sigma_{1,i}(0) = \cdots = \sigma_{L,i}(0)$ とする．このとき，隣り合う層の二次統計は固有ベクトルだけでなく固有値もそろい，$\boldsymbol{W}_\ell \boldsymbol{W}_\ell^\top = \boldsymbol{W}_{\ell+1}^\top \boldsymbol{W}_{\ell+1}$ となる．これを balanced 条件と呼ぶ．この等しさは更新後も保たれるので，共通の値を $\sigma_i(t)$ と書けば $s_i = \sigma_i^L$ であり，

$$\frac{ds_i}{dt} = \eta L s_i^{2-2/L}(s_i^* - s_i) \tag{5.25}$$

となる．多層の重みを学習する問題が，各モードにつき一つの非線形微分方程式に帰着した．

5.2.2 Saxe 解：モードごとの学習曲線

二層のネットワークでは，式 (5.25) は

$$\frac{ds_i}{dt} = 2\eta s_i(s_i^* - s_i) \tag{5.26}$$

である．初期値を $s_{i,0} := s_i(0)$ とし，$0 < s_{i,0} < s_i^*$ とする．変数を分離すると，

$$\int_{s_{i,0}}^{s_i(t)} \frac{ds}{s(s_i^* - s)} = 2\eta t, \qquad \frac{1}{s_i^*} \log \frac{s_i(t)(s_i^* - s_{i,0})}{s_{i,0}(s_i^* - s_i(t))} = 2\eta t \tag{5.27}$$

となり，$s_i(t)$ について解けば，

$$s_i(t) = \frac{s_i^*}{1 + (s_i^*/s_{i,0} - 1)e^{-2\eta s_i^* t}} \tag{5.28}$$

を得る．これが，層間の大きさがそろった二層ネットワークに対する Saxe 解である．積行列と関数出力は，この $s_i(t)$ を式 (5.22) に戻すことで求まる．

この解は，小さい重みからの学習が初めは遅く，途中から速くなる理由を説明する．$s_i \ll s_i^*$ の間は $ds_i/dt \approx 2\eta s_i^* s_i$ であり，更新の速さ自体が現在の s_i に比例する．初期値が小さいほど，目標の大きさに達するまで時間がかかる．s_i が増えると変化も速くなり，最後は残差 $s_i^* - s_i$ が小さくなるため減速する．このため学習曲線は S 字形になる．

また，時間は指数の中で $\eta s_i^* t$ という組合せで現れる．初期の相対的な強さ $s_{i,0}/s_i^*$ をそろえて比較すると，s_i^* の大きいモードほど早く学習される．通常の勾配降下法は，目標の写像の強い成分から順に学習を進めるのである．より深いネットワークでも，式 (5.25) の $s_i^{2-2/L}$ が，小さい積行列からの学習速度を左右する．

5.2.3 Fukumizu 解：モードの結合を行列のまま解く

二層の場合について，ここでの Fukumizu 解は，Saxe 解と同じ白色化・balanced 条件を保ちながら，目標と重みの特異ベクトルがそろっていない初期値も扱う．隣り合う層の二次統計が可換という条件は共有し，目標に対するモードの向きと結合も行列のまま追う点で，Saxe 解を一般化している．二層ネットワークの勾配降下法を行列 Riccati 方程式へ書き直して解くのが，Fukumizu の方法である [22, 23]．

同じ損失のもとで，二つの重みの更新は

$$\frac{d\boldsymbol{W}_1}{dt} = \eta \boldsymbol{W}_2^\top (\boldsymbol{\Sigma}_{yx} - \boldsymbol{W}_{2:1}), \qquad \frac{d\boldsymbol{W}_2}{dt} = \eta (\boldsymbol{\Sigma}_{yx} - \boldsymbol{W}_{2:1}) \boldsymbol{W}_1^\top \tag{5.29}$$

となる．これから $\boldsymbol{W}_1 \boldsymbol{W}_1^\top - \boldsymbol{W}_2^\top \boldsymbol{W}_2$ を微分するとゼロになる．そこで，初期値に

$$\boldsymbol{W}_1(0) \boldsymbol{W}_1(0)^\top = \boldsymbol{W}_2(0)^\top \boldsymbol{W}_2(0) \tag{5.30}$$

を選ぶ．これは，前項の Saxe 解で置いた balanced 条件を二層の場合に書いたものである．両層の二次統計が等しいので，式 (5.23) の可換性も成り立つ．この条件は隠れ層での両層の対応を定め，目標 $\boldsymbol{\Sigma}_{yx}$ に対する特異ベクトルの向きは自由に選べる．

二つの重みを一つにまとめるため，

$$\boldsymbol{Z} := \begin{pmatrix} \boldsymbol{W}_1^\top \\ \boldsymbol{W}_2 \end{pmatrix}, \qquad \boldsymbol{K} := \begin{pmatrix} \boldsymbol{0} & \boldsymbol{\Sigma}_{yx}^\top \\ \boldsymbol{\Sigma}_{yx} & \boldsymbol{0} \end{pmatrix}, \qquad \boldsymbol{P} := \boldsymbol{Z}\boldsymbol{Z}^\top \tag{5.31}$$

とおく．$\boldsymbol{Z}$ は $2n \times n$，$\boldsymbol{K}$ と $\boldsymbol{P}$ は $2n \times 2n$ の行列である．balanced の条件を使うと，式 (5.29) は $d\boldsymbol{Z}/dt = \eta \boldsymbol{K}\boldsymbol{Z} - (\eta/2)\boldsymbol{Z}\boldsymbol{Z}^\top \boldsymbol{Z}$ とまとまる．両側から $\boldsymbol{Z}^\top$，$\boldsymbol{Z}$ を掛けて積を微分すれば，

$$\frac{d\boldsymbol{P}}{dt} = \eta (\boldsymbol{K}\boldsymbol{P} + \boldsymbol{P}\boldsymbol{K} - \boldsymbol{P}^2) \tag{5.32}$$

を得る．未知の行列の二次の項を含むこの形を，行列 Riccati 方程式という．

この方程式は，行列指数関数を使って解ける．$\boldsymbol{Z}_0 := \boldsymbol{Z}(0)$，$\boldsymbol{E}(t) := e^{\eta \boldsymbol{K} t}$ とおくと，解は

$$\begin{aligned} \boldsymbol{B}(t) &:= \boldsymbol{I} + \eta \int_0^t \boldsymbol{Z}_0^\top e^{2\eta \boldsymbol{K} \tau} \boldsymbol{Z}_0 \, d\tau, \\ \boldsymbol{P}(t) &= \boldsymbol{E}(t) \boldsymbol{Z}_0 \boldsymbol{B}(t)^{-1} \boldsymbol{Z}_0^\top \boldsymbol{E}(t) \end{aligned} \tag{5.33}$$

である[2)]．ここで求めた $\boldsymbol{P}$ の中には，

$$\boldsymbol{P}(t) = \begin{pmatrix} \boldsymbol{W}_1^\top \boldsymbol{W}_1 & \boldsymbol{W}_{2:1}^\top \\ \boldsymbol{W}_{2:1} & \boldsymbol{W}_2 \boldsymbol{W}_2^\top \end{pmatrix} \tag{5.34}$$

のように，重みの積と各層の二次統計が含まれている．左下のブロックを取り出せば，積行列，したがって関数出力の時間変化が分かる．初期の向きが目標とずれている場合の，モード間の結合もこの行列解に含まれる．

Saxe 解で置いた目標との整列は，この拡大した行列では

$$[\boldsymbol{K}, \boldsymbol{P}(0)] = \boldsymbol{0} \tag{5.35}$$

という可換性も与える．この場合，目標と初期値を同じ基底で対角化でき，行列解はモードごとに分かれる．層間の大きさもそろっていれば，第 i モードの分子は $s_{i,0} e^{2\eta s_i^* t}$，分母は

2) $\boldsymbol{K}$ は対称なので，$d\boldsymbol{B}/dt = \eta \boldsymbol{Z}_0^\top \boldsymbol{E}(t)^2 \boldsymbol{Z}_0$ と逆行列の微分公式を使うと，式 (5.32) を満たすことを直接確かめられる．

$1 + (s_{i,0}/s_i^*)(e^{2\eta s_i^* t} - 1)$ となり，式 (5.28) に一致する．Fukumizu 解は，同じ balanced 条件のもとで一般の初期値 $\boldsymbol{P}(0)$ を受け取り，目標に対する向きやモード間の結合も含めて積行列の変化を記述する．その初期値を目標と整列させた場合が，モードごとの学習速度を読み取りやすい Saxe 解である．

5.3 前処理勾配法における Saxe Solution

前節と同じく特異ベクトルを目標にそろえ，各層のモードの大きさを $\sigma_i(t) > 0$ にそろえる．積行列の特異値は $s_i = \sigma_i^L$ である．この設定で，前処理によって Saxe の力学系がどう変わるかを調べる．

5.3.1 NGD：積行列の誤差に比例する更新

5.1 節の自然勾配法をモードごとに書くと，各層は

$$\frac{d\sigma_i}{dt} = \frac{\eta}{L}\frac{s_i^* - s_i}{\sigma_i^{L-1}}, \qquad \frac{ds_i}{dt} = \eta(s_i^* - s_i) \tag{5.36}$$

に従う．通常の勾配降下法にあった $s_i^{2-2/L}$ の因子が取り除かれた．したがって，Saxe 解に対応する積行列の特異値の解は

$$s_i(t) = s_i^* + (s_{i,0} - s_i^*)e^{-\eta t}, \qquad \sigma_i(t) = \left[s_i^* + (s_{i,0} - s_i^*)e^{-\eta t}\right]^{1/L} \tag{5.37}$$

となる [20, 24]．各モードの残差は同じ率で減少し，小さい初期値から始めたことによる S 字形の遅れが消える．初期の残差に対する比 $(s_i^* - s_i(t))/(s_i^* - s_{i,0})$ は，目標の特異値 s_i^* によらず $e^{-\eta t}$ である．これは，前処理が各層の勾配の大きさを補正し，積行列が目標までの距離に比例する速さで動くようにしていることを表す．

5.3.2 Muon：各層の特異値を一定の速さで動かす更新

Muon については，第 2 章で説明した，momentum を使わず直交化を厳密に行う更新を考える．この設定では SpectralGD と一致する．式 (5.24) から，各層の勾配の第 i モードの成分は $\sigma_i^{L-1}(s_i - s_i^*)$ である．この成分の絶対値を 1 にそろえると，残るのは $s_i - s_i^*$ の符号なので，

$$\frac{d\sigma_i}{dt} = \eta\,\mathrm{sign}(s_i^* - s_i), \qquad \frac{ds_i}{dt} = \eta L s_i^{1-1/L}\,\mathrm{sign}(s_i^* - s_i) \tag{5.38}$$

となる [25]．初期値が $0 < s_{i,0} < s_i^*$ なら，到達前はすべてのモードで $d\sigma_i/dt = \eta$ である．目標に達した成分の更新をゼロとすると，解は

$$\sigma_i(t) = \min\{s_{i,0}^{1/L} + \eta t,\ (s_i^*)^{1/L}\}, \qquad s_i(t) = \min\{(s_{i,0}^{1/L} + \eta t)^L,\ s_i^*\} \tag{5.39}$$

と求まる[3]．各層の特異値は直線的に増え，積行列の特異値はその L 乗として増える．目標への到達時刻は

$$T_i = \frac{(s_i^*)^{1/L} - s_{i,0}^{1/L}}{\eta} \tag{5.40}$$

である．小さい正の初期値からの極限では，二層なら $s_i(t) = \min\{\eta^2 t^2, s_i^*\}$ となる．通常の勾配降下法で初期値の小ささが生む長い遅れが消え，目標の大きさによる到達時間の違いは $(s_i^*)^{1/L}$ を通じて現れる．

二つの前処理は，異なる量の変化をそろえている．NGD では，積行列の各モードの残差が同じ割合で減る．Muon では，目標に達するまで各層の特異値が同じ速さで動く．二層の場合に，通常の勾配降下法，NGD，Muon の積行列の力学系を並べると，

$$\frac{ds_i}{dt} = \begin{cases} 2\eta s_i(s_i^* - s_i), & \text{勾配降下法,} \\ \eta(s_i^* - s_i), & \text{NGD,} \\ 2\eta\sqrt{s_i}\,\mathrm{sign}(s_i^* - s_i), & \text{Muon} \end{cases} \tag{5.41}$$

となる．線形ネットワークでは，このように重みの積の力学系へ直すことで，前処理が学習の進み方をどう変えるかを具体的に読み取れる．

3) ここでは連続時間の更新を考えている．有限の学習率で符号方向へ更新する場合は，目標を越えて動くことがある．

第 6 章　学習レジーム

第 5 章では，線形ネットワークの出力が学習によってどう変わるかを調べた．非線形の活性化関数を持つネットワークでも，初期値のまわりで出力を線形近似すると，学習の進み方を具体的に計算できる場合がある．まず，この近似が学習中も成り立つ NTK regime[26, 27] を考え，通常の勾配降下法と自然勾配法を比較する．

6.1　Neural Tangent Kernel

6.1.1　NTK regime と線形化された学習ダイナミクス

非線形ネットワークの学習が複雑になる理由の一つは，パラメータを変えると，出力のパラメータに対する感度も変わることである．この感度を表すヤコビ行列がほぼ変わらないなら，学習はどう進むだろうか．まず出力の時間変化を求め，その後で，ヤコビ行列を初期値で固定できる設定を考える．

訓練データを $\{(\boldsymbol{x}_i, \boldsymbol{y}_i)\}_{i=1}^N$，ネットワークの出力を $\boldsymbol{f}_{\boldsymbol{\theta}}(\boldsymbol{x}) \in \mathbb{R}^c$ とする．$\boldsymbol{\theta} \in \mathbb{R}^d$ は各層の重み $\boldsymbol{W}_\ell$ とバイアスを並べたパラメータベクトルである．第 5 章と同じく連続時間 t を使い，訓練入力に対する出力と正解を縦に並べて，

$$\boldsymbol{f}_t := \begin{pmatrix} \boldsymbol{f}_{\boldsymbol{\theta}(t)}(\boldsymbol{x}_1) \\ \vdots \\ \boldsymbol{f}_{\boldsymbol{\theta}(t)}(\boldsymbol{x}_N) \end{pmatrix}, \qquad \boldsymbol{y} := \begin{pmatrix} \boldsymbol{y}_1 \\ \vdots \\ \boldsymbol{y}_N \end{pmatrix} \in \mathbb{R}^{Nc} \tag{6.1}$$

と書く．ここでは，二乗損失

$$\mathcal{L}(\boldsymbol{\theta}(t)) = \frac{1}{2N} \sum_{i=1}^{N} \| \boldsymbol{f}_{\boldsymbol{\theta}(t)}(\boldsymbol{x}_i) - \boldsymbol{y}_i \|_2^2 = \frac{1}{2N} \| \boldsymbol{f}_t - \boldsymbol{y} \|_2^2 \tag{6.2}$$

を最小にする．出力のヤコビ行列を

$$\boldsymbol{J}_t(\boldsymbol{x}) := \left. \frac{\partial \boldsymbol{f}_{\boldsymbol{\theta}}(\boldsymbol{x})}{\partial \boldsymbol{\theta}} \right|_{\boldsymbol{\theta}=\boldsymbol{\theta}(t)} \in \mathbb{R}^{c \times d}, \qquad \boldsymbol{J}_t := \begin{pmatrix} \boldsymbol{J}_t(\boldsymbol{x}_1) \\ \vdots \\ \boldsymbol{J}_t(\boldsymbol{x}_N) \end{pmatrix} \in \mathbb{R}^{Nc \times d} \tag{6.3}$$

とすると，連鎖律から損失の勾配は $\nabla_{\boldsymbol{\theta}} \mathcal{L} = \boldsymbol{J}_t^\top (\boldsymbol{f}_t - \boldsymbol{y})/N$ である．したがって，学習率 $\eta > 0$ の

勾配流と，それに伴う出力の変化は

$$\frac{d\boldsymbol{\theta}}{dt} = -\frac{\eta}{N}\boldsymbol{J}_t^\top(\boldsymbol{f}_t - \boldsymbol{y}), \tag{6.4}$$

$$\frac{d\boldsymbol{f}_t}{dt} = \boldsymbol{J}_t\frac{d\boldsymbol{\theta}}{dt} = -\eta\underbrace{\frac{1}{N}\boldsymbol{J}_t\boldsymbol{J}_t^\top}_{\boldsymbol{K}_t}(\boldsymbol{f}_t - \boldsymbol{y}) \tag{6.5}$$

となる．$\boldsymbol{K}_t \in \mathbb{R}^{Nc\times Nc}$ は，Neural Tangent Kernel（NTK）の訓練データ上の行列である．その (i,j) ブロックは $\boldsymbol{J}_t(\boldsymbol{x}_i)\boldsymbol{J}_t(\boldsymbol{x}_j)^\top/N$ であり，二つの入力に対する出力が，共通のパラメータ変化によってどれだけ一緒に動くかを表す．ここでは，損失の係数 $1/N$ を行列 $\boldsymbol{K}_t$ に含めている．式 (6.5) は出力についての式になったが，一般には $\boldsymbol{J}_t$，したがって $\boldsymbol{K}_t$ も学習中に変化する．

この行列を初期値で固定できる設定が NTK regime である．たとえば，全結合ネットワークを

$$\boldsymbol{h}_0 = \boldsymbol{x}, \qquad \boldsymbol{u}_\ell = \frac{\sigma_w}{\sqrt{M_{\ell-1}}}\boldsymbol{W}_\ell\boldsymbol{h}_{\ell-1} + \sigma_b\boldsymbol{b}_\ell, \qquad \boldsymbol{h}_\ell = \phi(\boldsymbol{u}_\ell) \tag{6.6}$$

と書く．活性化関数は隠れ層 $\ell = 1,\dots,L-1$ に適用し，最後の層の出力は $\boldsymbol{f}_{\boldsymbol{\theta}}(\boldsymbol{x}) = \boldsymbol{u}_L$ とする．M_ℓ は第 ℓ 層の幅であり，M_0 は入力次元，$M_L = c$ である．σ_w, σ_b は幅によらない係数とし，学習する $\boldsymbol{W}_\ell, \boldsymbol{b}_\ell$ の各成分を独立な標準正規分布で初期化する．このように，幅に依存する係数を順伝播の式に明示する書き方を NTK パラメータ化と呼ぶ．

訓練データ数，層数，出力次元を固定して隠れ層の幅を大きくすると，このパラメータ化のもとでは，学習中も $\boldsymbol{J}_t \approx \boldsymbol{J}_0$，$\boldsymbol{K}_t \approx \boldsymbol{K}_0$ とみなせる [26, 27][1)]．出力そのものは変化するが，パラメータを変えたときに出力が動く方向は，ほぼ初期値のまま保たれるのである．ヤコビ行列と NTK の変化を抑える証明は，付録にまとめた．そこで，初期パラメータ $\boldsymbol{\theta}_0 := \boldsymbol{\theta}(0)$ のまわりの一次近似

$$\boldsymbol{f}_{\boldsymbol{\theta}}^{\mathrm{lin}}(\boldsymbol{x}) := \boldsymbol{f}_{\boldsymbol{\theta}_0}(\boldsymbol{x}) + \boldsymbol{J}_0(\boldsymbol{x})(\boldsymbol{\theta} - \boldsymbol{\theta}_0) \tag{6.7}$$

を学習することで，元のネットワークの学習を近似できる．このモデルは，入力 $\boldsymbol{x}$ に対しては非線形でも，学習するパラメータの変化 $\boldsymbol{\theta} - \boldsymbol{\theta}_0$ に対しては線形である．

線形化モデルの訓練出力を $\boldsymbol{f}_t^{\mathrm{lin}}$ と書くと，ヤコビ行列は $\boldsymbol{J}_0$ で一定なので，式 (6.5) は

$$\frac{d\boldsymbol{f}_t^{\mathrm{lin}}}{dt} = -\eta\boldsymbol{K}_0(\boldsymbol{f}_t^{\mathrm{lin}} - \boldsymbol{y}) \tag{6.8}$$

となる．これは係数が一定の線形微分方程式である．残差 $\boldsymbol{f}_t^{\mathrm{lin}} - \boldsymbol{y}$ について解けば，

$$\boldsymbol{f}_t^{\mathrm{lin}} = \boldsymbol{y} + \exp(-\eta\boldsymbol{K}_0 t)(\boldsymbol{f}_0 - \boldsymbol{y}) \tag{6.9}$$

を得る．固有値 ν_i に対応する残差の成分は $\exp(-\eta\nu_i t)$ 倍になる．したがって，$\boldsymbol{K}_0$ が正定値なら訓練誤差はゼロに近づくが，小さい固有値に対応する成分の学習は遅い．第 4 章で損失の曲率に

1) 幅極限での主張には，活性化関数の滑らかさなどの条件がある．ここでは，それらの条件のもとでヤコビ行列の変化が小さくなる時間区間を考える．また，訓練誤差全体の収束を述べるときは，後で示すように $\boldsymbol{K}_0$ の正定値性を仮定する．

よって収束速度が変わったのと同じことが，ここでは出力の空間で起きている．離散時間の勾配降下法でも，線形化モデルでは

$$\boldsymbol{f}^{\mathrm{lin},(k)} - \boldsymbol{y} = (\boldsymbol{I} - \eta \boldsymbol{K}_0)^k (\boldsymbol{f}_0 - \boldsymbol{y}) \tag{6.10}$$

と書ける．$\boldsymbol{K}_0$ が正定値なら，$0 < \eta < 2/\nu_{\max}$ の範囲で収束する．

6.1.2 NTK regime での自然勾配法

通常の勾配降下法では，$\boldsymbol{K}_0$ の固有値ごとに出力の収束速度が異なった．自然勾配法は，この違いをどう変えるのだろうか．第 5 章と同じく，予測分布を固定共分散の正規分布として，ここでは

$$p_{\boldsymbol{\theta}}(\boldsymbol{y} \mid \boldsymbol{x}) = \mathcal{N}(\boldsymbol{y}; \boldsymbol{f}_{\boldsymbol{\theta}}(\boldsymbol{x}), \boldsymbol{I}_c) \tag{6.11}$$

と選ぶ．訓練入力上の一様な経験分布を μ とすると，負の対数尤度は定数を除いて式 (6.2) の二乗損失であり，フィッシャー情報行列は

$$\boldsymbol{F}_t = \frac{1}{N} \sum_{i=1}^{N} \boldsymbol{J}_t(\boldsymbol{x}_i)^\top \boldsymbol{J}_t(\boldsymbol{x}_i) = \frac{1}{N} \boldsymbol{J}_t^\top \boldsymbol{J}_t \tag{6.12}$$

となる．ここで，入力は訓練データで平均し，出力はモデルの正規分布で平均している．$\boldsymbol{K}_t$ が出力の空間の $Nc \times Nc$ 行列であるのに対し，$\boldsymbol{F}_t$ はパラメータの空間の $d \times d$ 行列である．両者は，同じヤコビ行列の積の順序を入れ替えたものになっている．

幅の広いネットワークでは $d > Nc$ となり，$\boldsymbol{F}_t$ は特異になる．そこで第 5 章と同様に，自然勾配の方向を $\boldsymbol{F}_t \boldsymbol{v}_t = \nabla \mathcal{L}$ の解として求める．その最小ノルム解を，擬似逆行列 $\boldsymbol{F}_t^+$ を使って $\boldsymbol{v}_t = \boldsymbol{F}_t^+ \nabla \mathcal{L}$ と書く．$\boldsymbol{F}_t^+$ は，正の固有値を逆数にし，ゼロ固有値をゼロのまま残した行列である．自然勾配流では

$$\frac{d\boldsymbol{\theta}}{dt} = -\eta \boldsymbol{F}_t^+ \nabla \mathcal{L}, \qquad \frac{d\boldsymbol{f}_t}{dt} = -\frac{\eta}{N} \boldsymbol{J}_t \boldsymbol{F}_t^+ \boldsymbol{J}_t^\top (\boldsymbol{f}_t - \boldsymbol{y}) \tag{6.13}$$

となる．つまり，出力の変化を決める行列が，通常の NTK から $\boldsymbol{J}_t \boldsymbol{F}_t^+ \boldsymbol{J}_t^\top / N$ に変わる．

NTK regime でヤコビ行列を $\boldsymbol{J}_0$ に固定し，この行列を計算する．正の特異値だけを残した分解を $\boldsymbol{J}_0 = \boldsymbol{U} \boldsymbol{\Sigma} \boldsymbol{V}^\top$ と書くと，

$$\boldsymbol{F}_0^+ = N \boldsymbol{V} \boldsymbol{\Sigma}^{-2} \boldsymbol{V}^\top, \qquad \frac{1}{N} \boldsymbol{J}_0 \boldsymbol{F}_0^+ \boldsymbol{J}_0^\top = \boldsymbol{U} \boldsymbol{U}^\top \tag{6.14}$$

を得る．$\boldsymbol{K}_0 \succ \boldsymbol{0}$ なら，$\boldsymbol{J}_0$ は行フルランクなので，$\boldsymbol{U}\boldsymbol{U}^\top = \boldsymbol{I}_{Nc}$ である．したがって，線形化モデルの自然勾配流とその解は

$$\frac{d\boldsymbol{f}_t^{\mathrm{lin}}}{dt} = -\eta (\boldsymbol{f}_t^{\mathrm{lin}} - \boldsymbol{y}), \qquad \boldsymbol{f}_t^{\mathrm{lin}} = \boldsymbol{y} + e^{-\eta t} (\boldsymbol{f}_0 - \boldsymbol{y}) \tag{6.15}$$

となる [28]．通常の勾配降下法では $\boldsymbol{K}_0$ の固有値に依存していた収束速度が，すべての訓練出力の方向で同じになる．離散時間でも残差は $(1-\eta)^k (\boldsymbol{f}_0 - \boldsymbol{y})$ となり，線形化モデルでは $\eta = 1$ の一回の更新で訓練出力が正解に一致する．学習の速さを見ている対象は，各パラメータではなく訓練入力上の関数出力である．

damping を加えた場合も，出力のダイナミクスからその効果がわかる．$\boldsymbol{F}_0^+$ の代わりに $(\boldsymbol{F}_0 + \gamma \boldsymbol{I})^{-1}$（$\gamma > 0$）を使うと，出力の変化を決める行列は

$$\frac{1}{N} \boldsymbol{J}_0 (\boldsymbol{F}_0 + \gamma \boldsymbol{I})^{-1} \boldsymbol{J}_0^\top = \boldsymbol{K}_0 (\boldsymbol{K}_0 + \gamma \boldsymbol{I})^{-1} \tag{6.16}$$

となる．$\boldsymbol{K}_0$ の固有値 ν_i に対応する収束速度は $\eta \nu_i / (\nu_i + \gamma)$ である．damping をゼロに近づけると速度が η にそろい，damping が大きいと，小さい固有値の方向の更新がより強く抑えられる．

第 5 章の線形ネットワークと同様に，NTK regime でも，自然勾配法による学習は関数出力の指数収束として理解できる．damping のない極限では，訓練入力上の出力と正解の差が，どの方向でも同じ $e^{-\eta t}$ の割合で減衰する．自然勾配による前処理は，NTK の固有値に依存した学習速度の違いを取り除き，関数出力を一様な速度で正解へ近づけるのである．

6.2 特徴学習

第 7 章　ホップフィールドネットワーク

第 8 章　ハイパーパラメータの設定

付録 A　NTK regime の保証

第 6 章では，NTK regime で学習中も $\boldsymbol{J}_t \approx \boldsymbol{J}_0$，$\boldsymbol{K}_t \approx \boldsymbol{K}_0$ とみなせることを使った．この付録では，Lee ら [27] の証明に沿って，ヤコビ行列の局所的な評価から，学習の全時間にわたる評価を導く．局所評価そのものも計算で確かめられるように，まず二層ネットワークを扱う．証明は，初期値近傍でのヤコビ行列の変化を評価し，次に学習軌道がその近傍に留まることを示す，という順に進める．最後に，線形化モデルとの出力の差も評価する．

A.1　二層ネットワークでの局所評価

隠れ層の幅を M，出力をスカラーとし，

$$f_{\boldsymbol{\theta}}(\boldsymbol{x}) = \frac{1}{\sqrt{M}} \sum_{j=1}^{M} a_j \phi(\boldsymbol{w}_j^\top \boldsymbol{x}) = \frac{1}{\sqrt{M}} \boldsymbol{W}_2 \phi(\boldsymbol{W}_1 \boldsymbol{x}) \tag{A.1}$$

と書く．$\boldsymbol{w}_j^\top$ は $\boldsymbol{W}_1$ の第 j 行，a_j は $\boldsymbol{W}_2$ の第 j 成分であり，$\boldsymbol{\theta}$ は両方の重みを並べたベクトルである．入力次元だけに依存する規格化係数は，入力の尺度に含めている．訓練入力は $\|\boldsymbol{x}_i\|_2 \le 1$ とし，データ数 N は幅 M によらず固定する．活性化関数は二階連続微分可能で，ある $C_\phi \ge 1$ に対して

$$|\phi(u)|, \quad |\phi'(u)|, \quad |\phi''(u)| \le C_\phi \qquad (u \in \mathbb{R}) \tag{A.2}$$

とする．たとえば tanh はこの条件を満たす．

出力を訓練入力上で並べたベクトルを $\boldsymbol{f}(\boldsymbol{\theta}) \in \mathbb{R}^N$，そのヤコビ行列を $\boldsymbol{J}(\boldsymbol{\theta})$ とし，

$$\boldsymbol{J}(\boldsymbol{\theta}) := \frac{\partial \boldsymbol{f}(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}}, \qquad \boldsymbol{K}(\boldsymbol{\theta}) := \frac{1}{N} \boldsymbol{J}(\boldsymbol{\theta}) \boldsymbol{J}(\boldsymbol{\theta})^\top \tag{A.3}$$

と定める．第 6 章と同じく，NTK 行列には損失の係数 $1/N$ を含めている．初期値を $\boldsymbol{\theta}_0$，各ユニットの出力側の初期重みを $a_{j,0}$ と書く．ここでは，

$$\frac{1}{M} \sum_{j=1}^{M} a_{j,0}^2 \le 2, \qquad A_M := \max_{1 \le j \le M} |a_{j,0}| \tag{A.4}$$

を満たす初期値を考える．ガウス初期値でこの条件が成り立つ確率は，後で確認する．

幅によらない半径 $R > 0$ の球 $\|\boldsymbol{\theta} - \boldsymbol{\theta}_0\|_2 \le R$ を考える．まず，$M \ge R^2$ なら，この球の中で

$$\frac{1}{M} \sum_j a_j^2 \le \frac{2}{M} \sum_j a_{j,0}^2 + \frac{2}{M} \sum_j (a_j - a_{j,0})^2 \le 4 + \frac{2R^2}{M} \le 6 \tag{A.5}$$

となる．一方，一つの入力に対する出力の微分は，$u_j = \boldsymbol{w}_j^\top \boldsymbol{x}$ とおくと

$$\frac{\partial f_{\boldsymbol{\theta}}(\boldsymbol{x})}{\partial a_j} = \frac{\phi(u_j)}{\sqrt{M}}, \qquad \nabla_{\boldsymbol{w}_j} f_{\boldsymbol{\theta}}(\boldsymbol{x}) = \frac{a_j \phi'(u_j)}{\sqrt{M}} \boldsymbol{x} \tag{A.6}$$

である．これらの成分の二乗を足すと，式 (A.5) から

$$\|\boldsymbol{J}(\boldsymbol{\theta})\|_{\mathrm{F}}^2 \le \sum_{i=1}^{N} \frac{C_\phi^2}{M} \sum_j (1 + a_j^2) \le 7NC_\phi^2 =: B^2 \tag{A.7}$$

を得る．B は幅 M によらない．

次に，ヤコビ行列がどれだけ変わるかを評価する．パラメータをユニットごとに並べ替えると，出力のヘッセ行列は，$(a_j, \boldsymbol{w}_j)$ に対応するブロック

$$\frac{1}{\sqrt{M}} \begin{pmatrix} 0 & \phi'(u_j)\boldsymbol{x}^\top \\ \phi'(u_j)\boldsymbol{x} & a_j \phi''(u_j)\boldsymbol{x}\boldsymbol{x}^\top \end{pmatrix} \tag{A.8}$$

を持つブロック対角行列になる．各ブロックの作用素ノルムは $C_\phi(2 + |a_j|)/\sqrt{M}$ 以下であり，球の中では $|a_j| \le A_M + R$ である．したがって，一つの出力のヘッセ行列の作用素ノルムは $3C_\phi(1 + A_M + R)/\sqrt{M}$ 以下になる．二つの点 $\boldsymbol{\theta}, \widetilde{\boldsymbol{\theta}}$ を結ぶ線分に沿って微分を積分し，訓練入力 N 個について足し合わせると，

$$\|\boldsymbol{J}(\boldsymbol{\theta}) - \boldsymbol{J}(\widetilde{\boldsymbol{\theta}})\|_{\mathrm{F}} \le \varepsilon_M \|\boldsymbol{\theta} - \widetilde{\boldsymbol{\theta}}\|_2, \qquad \varepsilon_M := \frac{3C_\phi \sqrt{N}(1 + A_M + R)}{\sqrt{M}} \tag{A.9}$$

を得る．$A_M/\sqrt{M} \to 0$ なら，$\varepsilon_M \to 0$ である．つまり，初期値から幅によらない距離だけパラメータを動かしても，ヤコビ行列の変化は幅とともに小さくなる．

A.2　学習軌道が初期値近傍に留まること

局所評価が得られても，学習軌道が球から出てしまえば，その評価は使い続けられない．ここでは，残差の減衰を使って，学習軌道が球の内側に留まることを示す．この部分で使うのは，ヤコビ行列の上界 B と局所リプシッツ係数 ε_M だけであり，二層という構造には依存しない．

第 6 章と同じ二乗損失と勾配流を考え，残差を $\boldsymbol{e}_t := \boldsymbol{f}(\boldsymbol{\theta}(t)) - \boldsymbol{y}$ と書く．すると，

$$\frac{d\boldsymbol{\theta}}{dt} = -\frac{\eta}{N} \boldsymbol{J}_t^\top \boldsymbol{e}_t, \qquad \frac{d\boldsymbol{e}_t}{dt} = -\eta \boldsymbol{K}_t \boldsymbol{e}_t \tag{A.10}$$

である．初期値で $\|\boldsymbol{e}_0\|_2 \le E$（$E > 0$），$\lambda_{\min}(\boldsymbol{K}_0) \ge \kappa > 0$ とし，E, κ は幅によらないものとする．球の半径を

$$R := \frac{4BE}{N\kappa} \tag{A.11}$$

と選び，この球で前節の局所評価が成り立つとする．

球の中では，NTK の差を

$$\begin{aligned}\|\boldsymbol{K}(\boldsymbol{\theta})-\boldsymbol{K}_0\|_{\mathrm{op}} &\le \frac{1}{N}\left(\|\boldsymbol{J}(\boldsymbol{\theta})\|_{\mathrm{op}}+\|\boldsymbol{J}_0\|_{\mathrm{op}}\right)\|\boldsymbol{J}(\boldsymbol{\theta})-\boldsymbol{J}_0\|_{\mathrm{op}} \\ &\le \frac{2B\varepsilon_M R}{N} =: \Delta_M \end{aligned} \tag{A.12}$$

と評価できる．ここでは，積の差を $(\boldsymbol{J}-\boldsymbol{J}_0)\boldsymbol{J}^\top+\boldsymbol{J}_0(\boldsymbol{J}-\boldsymbol{J}_0)^\top$ と分け，作用素ノルムがフロベニウスノルム以下であることを使った．幅を十分大きくして $\Delta_M \le \kappa/2$ とすれば，球の中で

$$\boldsymbol{K}(\boldsymbol{\theta}) \succeq \frac{\kappa}{2}\boldsymbol{I} \tag{A.13}$$

が成り立つ．

学習軌道が初めて球の境界に達する時刻を $\tau := \inf\{t \ge 0 : \|\boldsymbol{\theta}(t)-\boldsymbol{\theta}_0\|_2 = R\}$ とする．そのような時刻がなければ $\tau=\infty$ とする．$t<\tau$ では，式 (A.13) が使えるので，

$$\frac{d}{dt}\|\boldsymbol{e}_t\|_2^2 = -2\eta\boldsymbol{e}_t^\top\boldsymbol{K}_t\boldsymbol{e}_t \le -\eta\kappa\|\boldsymbol{e}_t\|_2^2, \qquad \|\boldsymbol{e}_t\|_2 \le Ee^{-\eta\kappa t/2} \tag{A.14}$$

となる．残差が減ると，パラメータの動く速さも小さくなる．実際，勾配流を積分すると，

$$\begin{aligned}\|\boldsymbol{\theta}(t)-\boldsymbol{\theta}_0\|_2 &\le \int_0^t \left\|\frac{d\boldsymbol{\theta}(s)}{ds}\right\|_2 ds \le \frac{\eta BE}{N}\int_0^t e^{-\eta\kappa s/2}\,ds \\ &= \frac{2BE}{N\kappa}(1-e^{-\eta\kappa t/2}) \le \frac{R}{2}\end{aligned} \tag{A.15}$$

を得る．もし $\tau<\infty$ なら，連続性により $t=\tau$ でも左辺は $R/2$ 以下である．これは境界に達したという τ の定義に反する．したがって $\tau=\infty$ であり，局所評価は学習の全時間で使える．

以上から，

$$\sup_{t\ge0}\|\boldsymbol{J}_t-\boldsymbol{J}_0\|_{\mathrm{F}} \le \varepsilon_M R, \qquad \sup_{t\ge0}\|\boldsymbol{K}_t-\boldsymbol{K}_0\|_{\mathrm{op}} \le \Delta_M \tag{A.16}$$

となる．$\varepsilon_M \to 0$ なら，両方の変化が学習の全時間にわたってゼロに近づく．パラメータ全体の移動量は幅によらない上界で抑えられ，ヤコビ行列と NTK の変化は幅とともに小さくなるのである．

A.3　ガウス初期値で条件を満たす確率

重み $a_{j,0}, \boldsymbol{w}_{j,0}$ の各成分を独立な標準正規分布で初期化する．大数の法則から $M^{-1}\sum_j a_{j,0}^2 \to 1$ なので，式 (A.4) の第 1 条件は，幅を大きくすると確率 1 に近づく．また，ガウス分布の尾部評価と和の上界から，任意の $\delta\in(0,1)$ に対して

$$\mathbb{P}\left(A_M > \sqrt{2\log\frac{2M}{\delta}}\right) \le \sum_{j=1}^{M} 2\exp\left(-\frac{1}{2}\,2\log\frac{2M}{\delta}\right) = \delta \tag{A.17}$$

となる．したがって，固定した δ について，局所リプシッツ係数は高い確率で

$$\varepsilon_M = O\left(\sqrt{\frac{\log M}{M}}\right) \longrightarrow 0 \tag{A.18}$$

と評価できる．この対数因子は，全ユニットの初期重みの最大値を使った評価から生じている．

初期残差にも，幅によらない確率的な上界を取れる．$a_{j,0}$ の平均がゼロで，ϕ は有界なので，一つの入力に対して $\mathbb{E}[f_{\boldsymbol{\theta}_0}(\boldsymbol{x})^2] \le C_\phi^2$ である．よって $\mathbb{E}\|\boldsymbol{e}_0\|_2^2 \le 2NC_\phi^2 + 2\|\boldsymbol{y}\|_2^2$ であり，Markov の不等式から，任意に高い確率で $\|\boldsymbol{e}_0\|_2 \le E$ となる定数 E を，幅と独立に選べる．

初期 NTK の各成分も，独立なユニットの寄与の平均である．そのため，大数の法則から，$\boldsymbol{K}_0$ は幅の増大とともに非ランダムな行列 $\boldsymbol{K}_\infty$ に収束する．ここで，訓練入力について $\boldsymbol{K}_\infty \succ \boldsymbol{0}$ と仮定する [26, 27]．$\kappa := \lambda_{\min}(\boldsymbol{K}_\infty)/2$ とおけば，幅を十分大きくすることで $\lambda_{\min}(\boldsymbol{K}_0) \ge \kappa$ も高い確率で成り立つ．以上の確率の上界を合わせると，任意の信頼水準 $1-\delta$ に対し，幅によらない B, E, κ, R を選び，十分大きな幅で前節の条件を同時に満たせる．その初期値では，式 (A.16) から，$\boldsymbol{J}_t - \boldsymbol{J}_0$ と $\boldsymbol{K}_t - \boldsymbol{K}_0$ はともに，学習の全時間で $O(\sqrt{\log M/M})$ に抑えられる．

A.4 線形化モデルとの出力の差

最後に，NTK を初期値で固定した式が，元のネットワークの学習を近似することを示す．元のネットワークの残差を $\boldsymbol{e}_t$，線形化モデルの残差を $\boldsymbol{e}_t^{\mathrm{lin}}$ とすると，

$$\frac{d\boldsymbol{e}_t}{dt} = -\eta \boldsymbol{K}_t \boldsymbol{e}_t, \qquad \frac{d\boldsymbol{e}_t^{\mathrm{lin}}}{dt} = -\eta \boldsymbol{K}_0 \boldsymbol{e}_t^{\mathrm{lin}}, \qquad \boldsymbol{e}_0^{\mathrm{lin}} = \boldsymbol{e}_0 \tag{A.19}$$

である．その差 $\boldsymbol{d}_t := \boldsymbol{e}_t - \boldsymbol{e}_t^{\mathrm{lin}}$ は

$$\frac{d\boldsymbol{d}_t}{dt} = -\eta \boldsymbol{K}_0 \boldsymbol{d}_t - \eta(\boldsymbol{K}_t - \boldsymbol{K}_0)\boldsymbol{e}_t, \qquad \boldsymbol{d}_0 = \boldsymbol{0} \tag{A.20}$$

を満たす．右辺の第 2 項が，NTK の変化によって生じるずれである．定数変化法により，

$$\boldsymbol{d}_t = -\eta \int_0^t e^{-\eta \boldsymbol{K}_0 (t-s)} (\boldsymbol{K}_s - \boldsymbol{K}_0)\boldsymbol{e}_s \, ds \tag{A.21}$$

となる．$\boldsymbol{K}_0 \succeq \kappa \boldsymbol{I}$，$\|\boldsymbol{e}_s\|_2 \le E$ と，NTK の一様な評価を使うと，

$$\|\boldsymbol{f}_t - \boldsymbol{f}_t^{\mathrm{lin}}\|_2 = \|\boldsymbol{d}_t\|_2 \le \eta \Delta_M E \int_0^t e^{-\eta\kappa(t-s)}\, ds \le \frac{\Delta_M E}{\kappa} \tag{A.22}$$

を得る．したがって，線形化モデルとの訓練出力の差も，学習の全時間にわたってゼロに近づく．

多層ネットワークでも，局所的なヤコビ行列の評価，残差の減衰，軌道の移動量の評価を組み合わせる証明の構造は同じである．Lee ら [27] は，層ごとの順伝播と逆伝播を使って対応する局所評価を行い，多層ネットワークの NTK の安定性と線形化モデルへの近さを示している．本付録の二層の計算では，$1/\sqrt{M}$ の係数によって出力のヘッセ行列が小さくなり，それがヤコビ行列の変化を小さくすることまで直接確認できた．

参考文献

[1] Panos Toulis, Dustin Tran, and Edo Airoldi. Towards stability and optimality in stochastic gradient descent. In *Proceedings of the 19th International Conference on Artificial Intelligence and Statistics*, volume 51 of *Proceedings of Machine Learning Research*, pages 1290–1298. PMLR, 2016.

[2] 渡辺澄夫. **ベイズ統計の理論と方法**. コロナ社, 2012.

[3] 赤池弘次. エントロピーとモデルの尤度. **日本物理学会誌**, 35(7):608–614, 1980.

[4] Roger Grosse. Metrics. CSC2541 Winter 2021 Lecture Notes Chapter 3, University of Toronto, 2021.

[5] Roger Grosse. Second-order optimization. CSC2541 Winter 2021 Lecture Notes Chapter 4, University of Toronto, 2021.

[6] James Martens. New insights and perspectives on the natural gradient method. *Journal of Machine Learning Research*, 21(146):1–76, 2020.

[7] Edoardo Urettini and Antonio Carta. Online curvature-aware replay: Leveraging 2nd order information for online continual learning. arXiv:2502.01866v1, 2025.

[8] Intel Corporation. Error analysis. Developer Reference for Intel oneAPI Math Kernel Library for Fortran, version 2026.0, 2026. https://www.intel.com/content/www/us/en/docs/onemkl/developer-reference-fortran/2026-0/error-analysis.html.

[9] Jeremy Bernstein and Laker Newhouse. Old optimizer, new norm: An anthology. arXiv:2409.20325v2, 2024.

[10] Keller Jordan. Muon: An optimizer for hidden layers in neural networks. https://kellerjordan.github.io/posts/muon/, 2024.

[11] Runa Eschenhagen, Anna Cai, Tsung-Hsien Lee, and Hao-Jun Michael Shi. Clarifying Shampoo: Adapting spectral descent to stochasticity and the parameter trajectory. arXiv:2602.09314v1, 2026.

[12] Vineet Gupta, Tomer Koren, and Yoram Singer. Shampoo: Preconditioned stochastic tensor optimization. In *Proceedings of the 35th International Conference on Machine Learning*, volume 80 of *Proceedings of Machine Learning Research*, pages 1842–1850. PMLR, 2018.

[13] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations*, 2015.

[14] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations*, 2019.

[15] John Duchi, Elad Hazan, and Yoram Singer. Adaptive subgradient methods for online learning

and stochastic optimization. *Journal of Machine Learning Research*, 12(61):2121–2159, 2011.

[16] Tijmen Tieleman and Geoffrey Hinton. Lecture 6.5—RMSProp: Divide the gradient by a running average of its recent magnitude. Neural Networks for Machine Learning, Coursera, 2012.

[17] Wu Lin, Scott C. Lowe, Felix Dangel, Runa Eschenhagen, Zikun Xu, and Roger B. Grosse. Understanding and improving Shampoo and SOAP via Kullback–Leibler minimization. arXiv:2509.03378v10, 2026.

[18] Roger Grosse. Adaptive gradient methods, normalization, and weight decay. CSC2541 Winter 2021 Lecture Notes Chapter 5, University of Toronto, 2021.

[19] Guodong Zhang, Lala Li, Zachary Nado, James Martens, Sushant Sachdeva, George E. Dahl, Christopher J. Shallue, and Roger Grosse. Which algorithmic choices matter at which batch sizes? Insights from a noisy quadratic model. In *Advances in Neural Information Processing Systems*, volume 32, 2019.

[20] Alberto Bernacchia, Máté Lengyel, and Guillaume Hennequin. Exact natural gradient in deep linear networks and its application to the nonlinear case. In *Advances in Neural Information Processing Systems*, volume 31, 2018.

[21] Andrew M. Saxe, James L. McClelland, and Surya Ganguli. Exact solutions to the nonlinear dynamics of learning in deep linear neural networks. In *International Conference on Learning Representations*, 2014.

[22] Kenji Fukumizu. Effect of batch learning in multilayer neural networks. In *Proceedings of the 5th International Conference on Neural Information Processing*, pages 67–70, 1998.

[23] Lukas Braun, Clémentine C. J. Dominé, James E. Fitzgerald, and Andrew M. Saxe. Exact learning dynamics of deep linear networks with prior knowledge. In *Advances in Neural Information Processing Systems*, volume 35, 2022.

[24] Dongsung Huh. Curvature-corrected learning dynamics in deep neural networks. In *Proceedings of the 37th International Conference on Machine Learning*, volume 119 of *Proceedings of Machine Learning Research*, pages 4552–4560. PMLR, 2020.

[25] Bhavya Vasudeva, Puneesh Deora, Yize Zhao, Vatsal Sharan, and Christos Thrampoulidis. How Muon's spectral design benefits generalization: A study on imbalanced data. In *International Conference on Learning Representations*, 2026.

[26] Arthur Jacot, Franck Gabriel, and Clément Hongler. Neural tangent kernel: Convergence and generalization in neural networks. In *Advances in Neural Information Processing Systems*, volume 31, 2018.

[27] Jaehoon Lee, Lechao Xiao, Samuel S. Schoenholz, Yasaman Bahri, Roman Novak, Jascha Sohl-Dickstein, and Jeffrey Pennington. Wide neural networks of any depth evolve as linear models under gradient descent. In *Advances in Neural Information Processing Systems*, volume 32, 2019.

[28] Ryo Karakida and Kazuki Osawa. Understanding approximate fisher information for fast convergence of natural gradient descent in wide neural networks. In *Advances in Neural Information*

Processing Systems, volume 33, 2020.